Universidade Estadual de Campinas
Instituto de Matemática, Estatística e Computação Científica

ME607 – Séries Temporais

Semestre 01/2026 – Trabalho Final

Modelagem SARIMA do Consumo de Eletricidade na Alemanha

Análise Completa de Séries Temporais
com Dados Mensais da OPSD/ENTSO-E (2015–2020)

Natalie Merk – RA: 300332

29 de junho de 2026

Resumo

Este trabalho apresenta uma análise estatística completa da série mensal de consumo total de eletricidade na Alemanha, obtida a partir do repositório *Open Power System Data* (OPSD), que agrega e publica os dados horários da *ENTSO-E Transparency Platform* num formato aberto e directamente descarregável [8]. A série cobre o período de janeiro de 2015 a setembro de 2020 (69 observações mensais), obtida por agregação dos valores horários em MWh/h para totais mensais em GWh. A série exibe forte sazonalidade anual determinada pelo ciclo de aquecimento e arrefecimento, uma tendência não linear, e uma intervenção estrutural identificável em março de 2020 associada à pandemia de COVID-19. A metodologia de Box-Jenkins [3] é seguida sistematicamente nas etapas de análise exploratória, decomposição sazonal, testes de estacionaridade, identificação, estimação e diagnóstico de modelos da classe SARIMA$(p, d, q)(P, D, Q)_{12}$. Toda a análise é conduzida em Python, utilizando pacotes como `statsmodels`, `pmdarima`, `pandas`, `matplotlib` e `scipy`. Uma discussão crítica das vantagens, limitações e extensões do modelo encerra o trabalho.

Palavras-chave: Consumo de Eletricidade; Alemanha; SARIMA; Sazonalidade; Análise de Intervenção; COVID-19; Box-Jenkins.

Conteúdo

1 Introdução **3**

2 Descrição dos Dados **4**

2.1 Fonte e Coleta 4

2.2 Descrição da Série 4

3 Análise Descritiva e Exploratória **5**

3.1 Visualização da Série 5

3.2 Estatísticas Descritivas 5

3.3 Decomposição STL 6

3.4 Funções de Autocorrelação 7

3.5 Testes de Estacionaridade 9

4 Modelo Base: Identificação e Estimação **12**

4.1 Identificação do Modelo por Critério de Informação 12

4.2 Seleção do Modelo 12

4.3 Estimação do Modelo Selecionado 18
4.4 Diagnóstico dos Resíduos 18

5 Extensão do Modelo: Análise de Intervenção 21
5.1 Verificação Preliminar 22
5.1.1 Modelo de Intervenção com Amostra Completa (pulso em março de 2020) 22
5.1.2 Teste de Intervenção via Modelo Pré-COVID 23
5.2 Estimação do Modelo com Intervenção Temporária e Gradual 25
5.3 Diagnóstico dos Resíduos 28

6 Comparação entre Modelos 31

7 Previsão 32

8 Discussão Crítica do Modelo 33
8.1 Vantagens 33
8.2 Desvantagens e Limitações 34
8.3 Extensões Recomendadas 36

9 Conclusão 37

Referências 37

Arquivos Supplementares 40

1. Introdução

A previsão e modelagem do consumo de energia elétrica constituem problemas de grande relevância prática para operadores de redes de transmissão, reguladores e formuladores de política energética. Séries de consumo elétrico apresentam características que as tornam particularmente adequadas para a metodologia de Box-Jenkins [7]: sazonalidade anual bem definida, tendência de médio prazo relacionada a fatores estruturais como eficiência energética e composição industrial, e perturbações exógenas identificáveis como recessões econômicas ou pandemias.

A Alemanha representa um caso de especial interesse neste contexto. Sendo a maior economia da Europa, seu sistema elétrico integra uma crescente parcela de energias renováveis (eólica e solar), cuja natureza intermitente torna a previsão de consumo ainda mais estratégica para o equilíbrio da rede [4, 8, 10]. Os dados são publicados pelo repositório *Open Power System Data* (OPSD), uma iniciativa académica europeia que agrega, limpa e redistribui os dados horários da *ENTSO-E Transparency Platform* num formato aberto, descarregável directamente em Python sem necessidade de registo ou chave de API.

Os objetivos deste trabalho são:

- Realizar uma análise descritiva e exploratória completa da série;
- Identificar e estimar um modelo SARIMA adequado seguindo a metodologia de Box, Jenkins e Reinsel [3];
- Conduzir análise de intervenção para o efeito da pandemia de COVID-19 (março de 2020), período em que se observa uma queda abrupta no consumo elétrico associada ao confinamento;
- Diagnosticar a adequação do modelo por meio de análise de resíduos;
- Produzir previsões para o horizonte de 12 meses;
- Discutir criticamente as vantagens, limitações e possíveis extensões.

O restante do relatório está organizado como segue. A Secção 2 descreve a fonte, o processo de recolha e as características da série. A Secção 3 apresenta a análise exploratória, incluindo a decomposição STL e as funções de autocorrelação. A Secção 4 trata da identificação, estimação e diagnóstico do modelo base, culminando na selecção do SARIMA$(0,1,1)(0,1,1)_{12}$. A Secção 5 apresenta a análise de intervenção para o efeito da pandemia de COVID-19, incluindo a verificação contrafactual e a estimação do modelo com pulso de decaimento exponencial. A Secção 6 compara os modelos com

e sem intervenção segundo os critérios de informação. A Secção 7 produz previsões para os 12 meses seguintes. A Secção 8 discute criticamente as vantagens, limitações e extensões recomendadas, e a Secção 9 encerra o trabalho com as conclusões.

2. Descrição dos Dados

2.1. Fonte e Coleta

Os dados são provenientes do repositório *Open Power System Data* (OPSD), disponível em `https://data.open-power-system-data.org/time_series/` [8]. O OPSD agrega os dados horários de carga real da *ENTSO-E Transparency Platform* e disponibiliza-os num único ficheiro CSV de acesso público e gratuito, sem necessidade de registo ou chave de API. A coluna utilizada é `DE_load_actual_entsoe_transparency`, que contém a carga horária em MWh/h para a Alemanha. Os dados horários são agregados em totais mensais em GWh por soma e divisão por 1 000. O período disponível cobre janeiro de 2015 a setembro de 2020 (69 observações mensais após remoção de meses incompletos). O descarregamento é efectuado directamente em Python, sem ficheiro intermédio.

2.2. Descrição da Série

A série abrange 69 observações mensais (janeiro de 2015 a setembro de 2020) e apresenta consumo variando entre 35 579 e 45 828 GWh, com média de 40 534 GWh/-mês. Os máximos ocorrem no inverno (dezembro–janeiro) e os mínimos no verão (julho–agosto), refletindo a demanda de aquecimento e o comportamento industrial. Observa-se uma tendência não linear com inversão em 2018–2019, associada ao aumento da eficiência energética e à integração crescente de energias renováveis na matriz alemã.

Os meses de março a setembro de 2020 apresentam consumo médio de 37,586 GWh, substancialmente inferior à média pré-COVID de 40,866 GWh, representando uma redução de aproximadamente 5%. Embora o primeiro caso de COVID-19 na Alemanha tenha sido registado a 27 de janeiro de 2020, o impacto no consumo elétrico só se torna visível a partir de março de 2020, mês em que foram implementadas as primeiras medidas de confinamento a nível nacional (22 de março de 2020). Por este motivo, março de 2020 é identificado como o ponto de intervenção do tipo pulso no modelo, e não janeiro, cujos valores de consumo se mantiveram dentro dos padrões históricos sazonais esperados.

3. Análise Descritiva e Exploratória

3.1. Visualização da Série

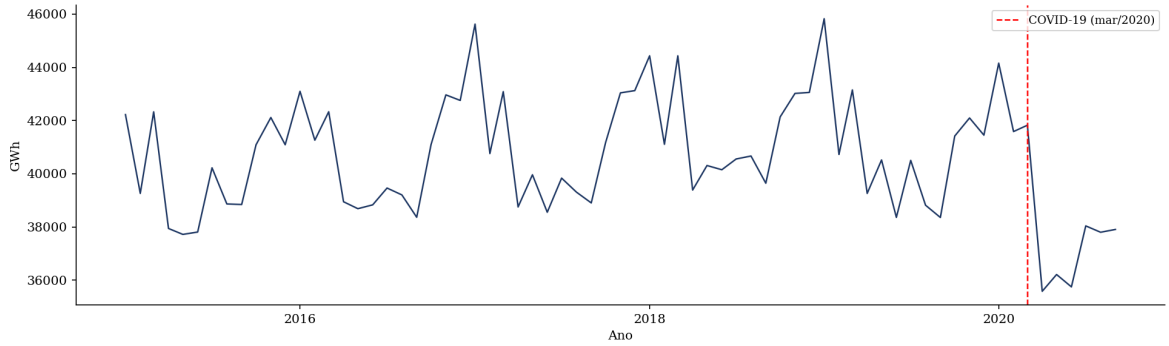


Figura 1. Série mensal de consumo de eletricidade na Alemanha (janeiro de 2015 a setembro de 2020), obtida por agregação dos dados horários OPSD/ENTSO-E. A linha tracejada vermelha indica o início do confinamento COVID-19 (março de 2020).

3.2. Estatísticas Descritivas

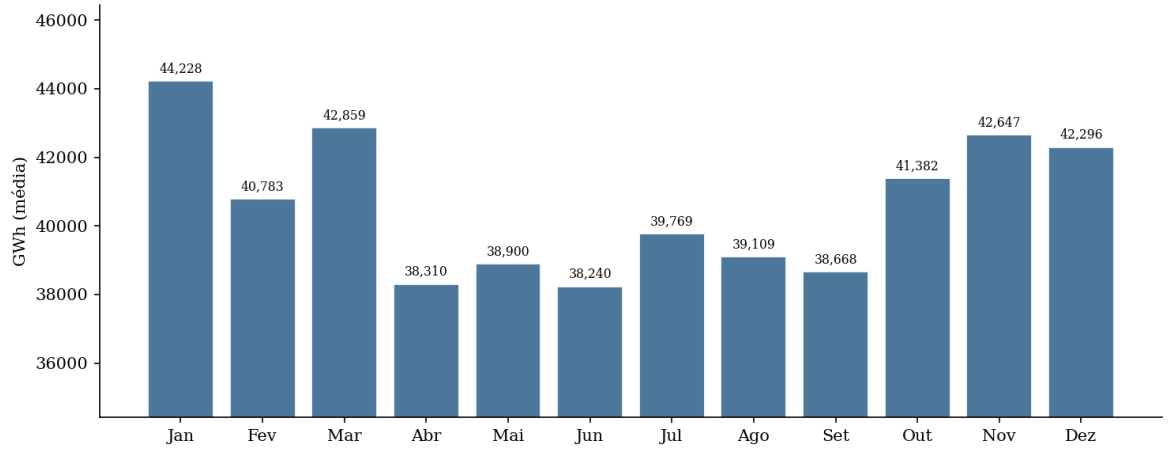


Figura 2. Perfil sazonal médio do consumo mensal de eletricidade na Alemanha (janeiro de 2015 a setembro de 2020). Os valores mais elevados ocorrem nos meses de inverno (dezembro–janeiro) e os mais baixos nos meses de verão (junho–agosto), refletindo a sazonalidade térmica da procura energética.



Figura 3. Heatmap do consumo médio mensal de energia elétrica (GWh) por ano e mês. As células mais escuras indicam maior consumo, enquanto células mais claras indicam menor consumo. Os valores representam a média mensal para cada combinação de ano e mês.

A Figura 2 apresenta o perfil sazonal médio do consumo por mês, obtido pela média das observações ao longo de todos os anos da amostra, enquanto a Figura 3 representa a evolução sazonal completa por meio de um mapa de calor organizado por mês e ano. Em conjunto, ambas as representações evidenciam uma estrutura de periodicidade anual ($s = 12$), sugerindo a presença de sazonalidade.

A Tabela 1 resume as estatísticas descritivas da série completa e por subperíodo (pré e pós-pandemia).

Tabela 1. Estatísticas descritivas da série (GWh).

Subperíodo	N	Média	Mediana	Desv. Pad.	Mínimo	Máximo
Jan/2015 – Fev/2020	62	40 867	40 695	1 997	37 718	45 828
Mar/2020 – Set/2020	7	37 586	37 799	2 146	35 579	41 824
Completo (Jan/2015 – Set/2020)	69	40 534	40 518	2 231	35 579	45 828

3.3. Decomposição STL

A decomposição STL (*Seasonal and Trend decomposition using Loess*) mostrado na figura 4 separa a série nos componentes de tendência, sazonalidade e resíduo [7]. A componente de tendência confirma o declínio gradual do consumo ao longo do período. A componente sazonal exibe padrão estável, com amplitude aproximada de 8 000–10 000 GWh entre o pico de inverno e o vale de verão (diferença entre dezembro e julho). A não linearidade da tendência tem implicações para a escolha do método de modelagem, discutidas nas Secções 3.5 e 8.2.

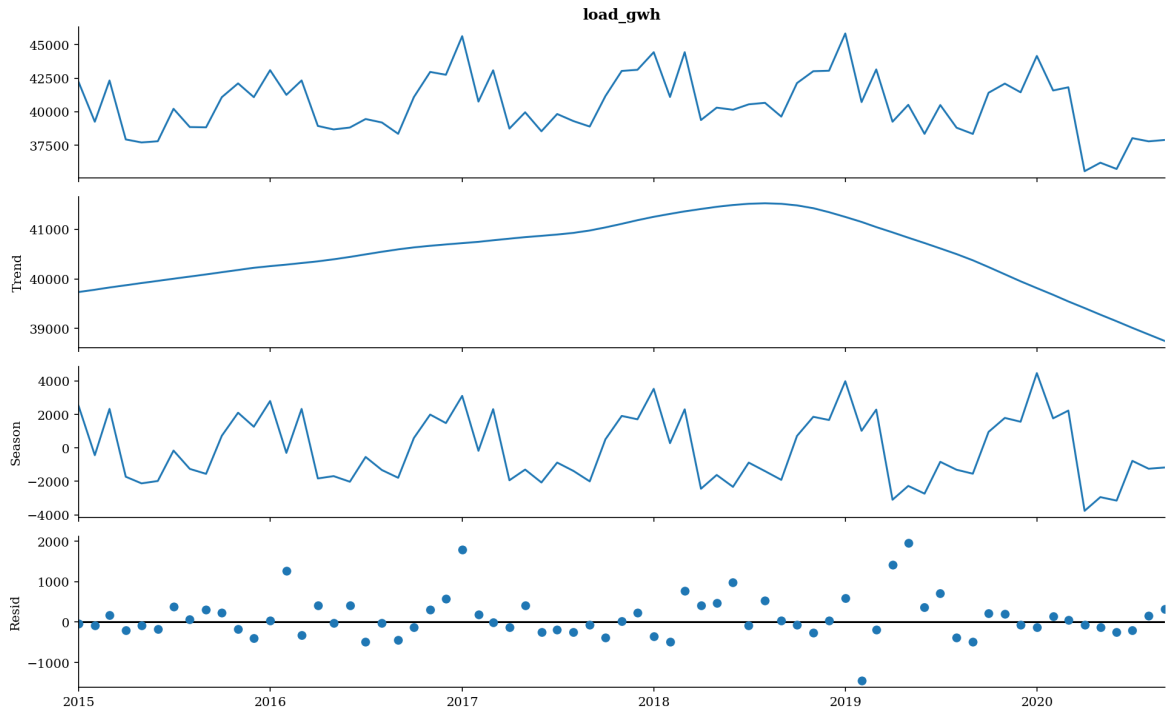


Figura 4. Decomposição STL da série mensal de consumo de eletricidade na Alemanha. Os painéis mostram (de cima para baixo): série original, tendência, componente sazonal e resíduo.

3.4. Funções de Autocorrelação

A Figura 5 apresenta as funções de autocorrelação (FAC) e autocorrelação parcial (FACP) para quatro versões da série: a série original, após diferenciação sazonal ($\nabla_{12} Y_t$), após diferenciação sazonal e regular ($\nabla\nabla_{12} Y_t$), e após diferenciação sazonal e dupla regular ($\nabla^2\nabla_{12} Y_t$). A análise conjunta destes painéis orienta tanto a verificação de estacionaridade como a identificação das ordens do modelo.

Na série original (painéis superiores), a FAC apresenta decaimento muito lento com autocorrelação de lag 1 próxima de +0,5 e picos persistentes nos lags múltiplos de 12, padrão característico de uma série não estacionária com tendência estocástica e forte componente sazonal. A FACP exibe um primeiro lag elevado ($\approx +0,5$) seguido de decaimento rápido, consistente com um processo integrado de ordem baixa.

Após diferenciação sazonal de ordem um ($\nabla_{12} Y_t$, painéis da segunda linha), os picos sazonais atenuam-se, mas a FAC continua a apresentar autocorrelação de lag 1 próxima de +0,5 com decaimento lento nos primeiros lags. Este padrão indica que a diferenciação sazonal isolada não foi suficiente para remover a dependência de curto prazo da série, motivando a aplicação de uma diferenciação regular adicional. Este diagnóstico é independente e anterior à comparação por critérios de informação.

Com diferenciação sazonal e regular ($\nabla\nabla_{12}Y_t$, terceira linha), o comportamento da FAC altera-se substancialmente. A autocorrelação de lag 1 passa a ser próxima de $-0{,}5$, padrão consistente com sobrediferenciação ligeira que corresponde à introdução de uma raiz MA próxima da fronteira de invertibilidade . Este artefacto é absorvido pelos termos MA do modelo SARIMA estimado e não compromete a adequação da especificação. Importa notar que o lag 12 apresenta um pico negativo significativo tanto na FAC como na FACP, suportando a inclusão de um termo MA sazonal de ordem Q=1. Os lags 1 e 2 da FAC são os dominantes nos lags curtos, o que é consistente com uma estrutura MA de ordem q=1 ou q=2 na componente regular.

A quarta linha ($\nabla^2\nabla_{12}Y_t$, quarta linha) confirma que d=2 não acrescenta informação útil: a FAC apresenta lag 1 igualmente próximo de $-0{,}5$, as bandas de confiança alargam-se devido à redução da amostra efectiva, e o padrão geral torna-se mais irregular. A especificação D=1, d=1 constitui portanto o equilíbrio adequado e é a que orienta a identificação dos modelos candidatos.

A FACP auxilia na identificação das ordens p, P. Dado o número de observações ($n = 69$), o número de *lags* representados é limitado automaticamente a $\lfloor n/2 \rfloor - 1 = 33$ (série original) e 27 (série diferenciada) para cumprir os requisitos do estimador de autocorrelação parcial.

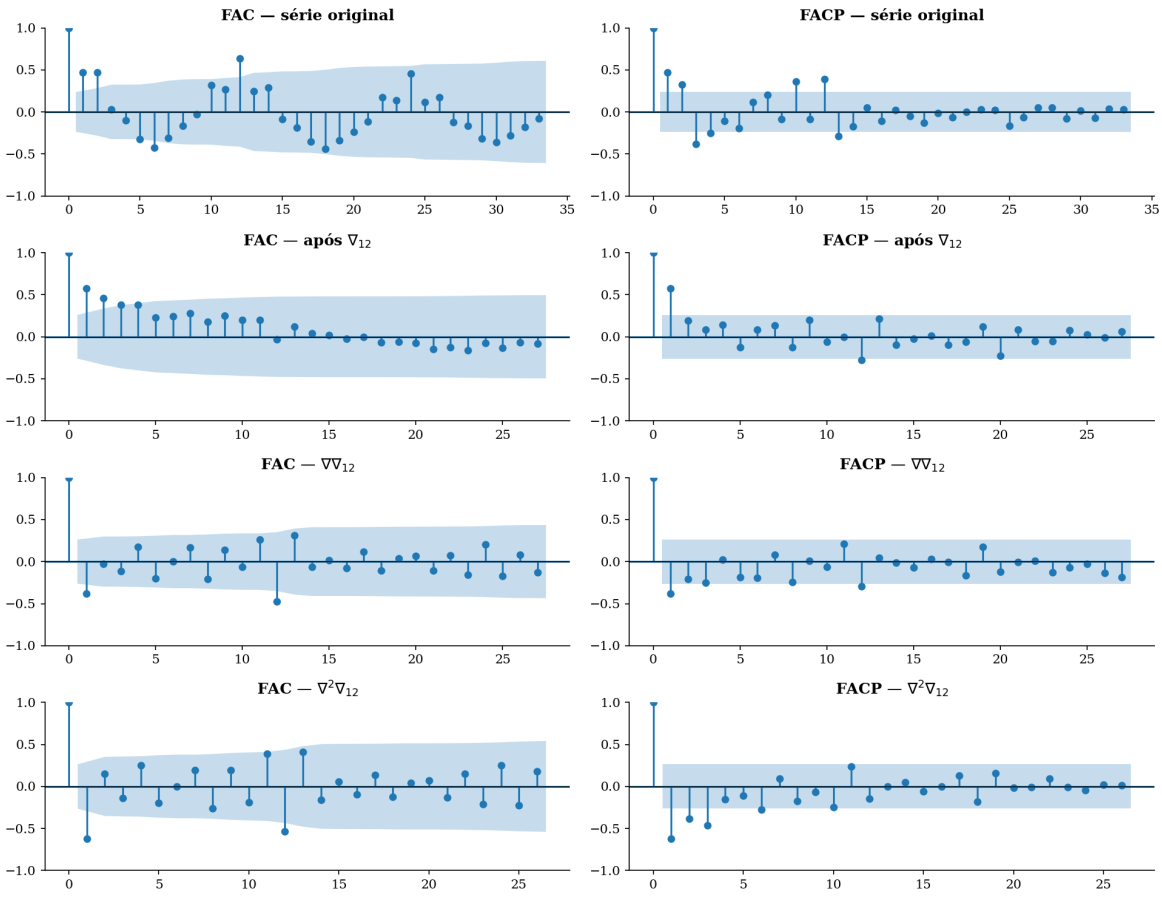


Figura 5. FAC e FACP da série original (primeira linha), após diferenciação sazonal de ordem um $\nabla_{12}Y_t$ (segunda linha), após diferenciação sazonal e regular de ordem um $\nabla\nabla_{12}Y_t$ (terceira linha), e após diferenciação sazonal e dupla regular $\nabla^2\nabla_{12}Y_t$ (quarta linha). A análise conjunta dos quatro painéis orienta a verificação de estacionaridade e a identificação das ordens do modelo.

3.5. Testes de Estacionaridade

A análise de estacionaridade foi conduzida com recurso aos testes Aumentado de Dickey-Fuller (ADF) e KPSS em conjunto para quatro versões da série. Os dois testes possuem hipóteses nulas opostas — o ADF testa a presença de raiz unitária enquanto o KPSS testa a estacionaridade em torno de uma constante — pelo que a sua utilização combinada permite conclusões mais robustas do que qualquer um dos testes isoladamente [3, capítulo 7.5.1]. Os resultados são apresentados na Tabela 2.

Tabela 2. Resultados dos testes ADF e KPSS para a série original e versões diferenciadas. Os dois testes possuem hipóteses nulas opostas: o ADF testa a presença de raiz unitária (H_0: não estacionária) enquanto o KPSS testa a estacionaridade em torno de uma constante (H_0: estacionária). A utilização conjunta permite conclusões mais robustas do que qualquer teste isoladamente.

Série	**ADF estat.**	**ADF** p	**KPSS estat.**	**KPSS** p	**Conclusão**
Original	0.0724	0.9641	0.1286	> 0.10	Ambíguo — FAC confirma não estacionaridade.
$\nabla_{12} Y_t$	-3.8304	0.0026	0.7873	< 0.01	Contradição ADF/KPSS — FAC confirma dependência residual; d=1 necessário.
$\nabla\nabla_{12} Y_t$	-2.4013	0.1414	0.1268	> 0.10	KPSS não rejeita H_0; ADF distorcido por sobrediferenciação ligeira (lag-1 FAC ≈ -0.5). Especificação adoptada.
$\nabla^2\nabla_{12} Y_t$	-3.4686	0.0088	0.2661	> 0.10	ADF rejeita a não estacionariedade e KPSS não rejeita a estacionariedade, mas FAC indica sobrediferenciação agravada. Rejeitado por parcimónia.

Para a série original, o ADF não rejeita H_0, indicando presença de raiz unitária, enquanto o KPSS também não rejeita H_0 ao nivel de 0.05. Esta combinação é ambígua pelos testes formais. Contudo, a FAC da série original (Figura 5, painéis superiores) apresenta decaimento muito lento e autocorrelação de lag 1 próxima de +0,5, confirmando não estacionaridade de forma inequívoca.

Após diferenciação sazonal de ordem um ($\nabla_{12} Y_t$), o ADF rejeita H_0, mas o KPSS também rejeita H_0 — os dois testes contradizem-se, configurando o caso de maior ambiguidade na literatura. A FAC de $\nabla_{12} Y_t$ (Figura 5, segunda linha) resolve a ambiguidade: a autocorrelação de lag 1 permanece próxima de +0,5 com decaimento lento, confirmando o diagnóstico do KPSS e indicando dependência de curto prazo residual. Este resultado, aliado à tendência não linear observada na decomposição STL (Figura 4) — que exibe um perfil em forma de U invertido entre 2015 e 2020 — é consistente com uma série que apresenta tendência não linear, para a qual o ADF tem poder reduzido. Conclui-se que a diferenciação sazonal isolada é insuficiente, motivando a aplicação de $d = 1$.

Com diferenciação sazonal e regular ($\nabla\nabla_{12}Y_t$), o KPSS não rejeita H_0, indicando estacionaridade, enquanto o ADF não rejeita H_0. A não rejeição do ADF neste caso não contradiz a estacionaridade: a FAC de $\nabla\nabla_{12}Y_t$ (Figura 5, terceira linha) apresenta autocorrelação de lag 1 próxima de $-0{,}5$, padrão diagnóstico de sobrediferenciação ligeira que introduz uma raiz MA próxima da fronteira de invertibilidade e reduz artificialmente o poder do ADF. Este artefacto é absorvido pelos termos MA do modelo SARIMA e não invalida a especificação $d = 1$.

A aplicação de $d = 2$ ($\nabla^2\nabla_{12}Y_t$) produz concordância entre ADF e KPSS, mas a FAC correspondente (Figura 5, quarta linha) apresenta o mesmo padrão de lag 1 próximo de $-0{,}5$ com bandas de confiança alargadas, evidenciando perda desnecessária de graus de liberdade.

A interpretação anterior é igualmente corroborada pela evolução da variância da série após cada transformação (Tabela 3). A diferenciação sazonal reduz substancialmente a variância relativamente à série original, refletindo a remoção da componente sazonal dominante. A aplicação de uma diferenciação regular adicional conduz a uma nova redução da variância, indicando uma estabilização acrescida da estrutura estocástica da série. Em contraste, a segunda diferenciação regular provoca um aumento expressivo da variância, aproximando-a novamente da observada na série original. Embora a variância, por si só, não constitua um critério de identificação da ordem de diferenciação, este comportamento é consistente com os resultados da FAC, sugerindo perda desnecessária de informação e sobrediferenciação quando se adopta $d = 2$. Assim, a evolução da variância fornece evidência complementar em favor da especificação com $D = 1$ e $d = 1$ [7, Capítulo 6.2].

A especificação $D = 1$, $d = 1$ é portanto, seleccionada como a que oferece o equilíbrio adequado entre remoção de não estacionaridade e parcimónia, orientando a identificação para modelos da classe SARIMA$(p, 1, q)(P, 1, Q)_{12}$.

Tabela 3. Variância da série original e das séries diferenciadas. A redução da variância após as diferenciações indica a remoção de componentes determinísticos, enquanto um aumento da variância pode ser um indício de sobrediferenciação.

Série	**Variância**
Original	4.907×10^6
$\nabla_{12}Y_t$	1.737×10^6
$\nabla\nabla_{12}Y_t$	1.479×10^6
$\nabla^2\nabla_{12}Y_t$	4.136×10^6

4. Modelo Base: Identificação e Estimação

4.1. Identificação do Modelo por Critério de Informação

Embora os testes de estacionaridade apresentados na Seção 3.4 indiquem que a combinação de uma diferenciação sazonal ($D = 1$) e de uma diferenciação regular ($d = 1$) é a mais adequada para induzir estacionaridade, permanece por identificar a estrutura autorregressiva e de médias móveis mais apropriada. Assim, foi considerado um conjunto de modelos candidatos da classe SARIMA$(p, 1, q)(P, 1, Q)_{12}$, com $p, q, P, Q \in \{0, 1, 2\}$.

A Tabela 4 apresenta os 40 melhores modelos candidatos ordenados segundo o critério de informação corrigido de Akaike (AICc). Observa-se que os modelos mais bem classificados apresentam diferenças reduzidas nos valores de AICc, refletindo desempenhos semelhantes em termos do compromisso entre qualidade de ajuste e complexidade do modelo.

4.2. Seleção do Modelo

Após a identificação inicial e a ordenação dos modelos candidatos segundo o critério AICc, procede-se à estimação e comparação detalhada de um conjunto reduzido de especificações concorrentes. Esta etapa segue o procedimento clássico de Box–Jenkins, no qual a seleção final do modelo não depende exclusivamente de critérios de informação, mas também da análise de diagnósticos dos resíduos, da significância estatística dos parâmetros e do princípio da parcimónia.

Os modelos com melhor desempenho segundo o AICc apresentam diferenças reduzidas entre si, sugerindo que pertencem a uma classe de especificações aproximadamente equivalentes em termos de qualidade de ajuste. Assim, a decisão final baseia-se na avaliação conjunta do comportamento dos resíduos (incluindo o teste de Ljung–Box), da estabilidade dos parâmetros estimados e da complexidade estrutural de cada modelo. Este procedimento permite garantir que o modelo selecionado não apenas apresenta bom ajuste in-sample, mas também satisfaz as condições necessárias para uma representação adequada do processo estocástico subjacente.

Para a seleção final do modelo, foi definido um conjunto alargado de especificações candidatas com base nos resultados obtidos na etapa de ordenação segundo o critério AICc. Em particular, foram considerados cinco modelos da classe SARIMA $(p, 1, q)(P, 1, Q)_{12}$, selecionados de forma a avaliar o impacto da complexidade adicional em ambas as componentes não sazonais e sazonais, bem como o efeito da ordem da

Tabela 4. Os 40 modelos candidatos com melhor desempenho segundo o critério AICc.

Rang	Modelo	Parâm.	AIC	AICc	BIC
1	$\text{SARIMA}(0,1,2)(0,1,2)_{12}$	5	486.92	489.53	493.76
2	$\text{SARIMA}(1,1,2)(0,1,2)_{12}$	6	486.37	490.19	494.57
3	$\text{SARIMA}(2,1,2)(0,1,2)_{12}$	7	485.55	490.89	495.12
4	$\text{SARIMA}(0,1,2)(1,1,2)_{12}$	6	487.74	491.55	495.94
5	$\text{SARIMA}(0,1,2)(2,1,2)_{12}$	7	486.66	492.00	496.24
6	$\text{SARIMA}(1,1,2)(1,1,2)_{12}$	7	489.55	494.89	499.13
7	$\text{SARIMA}(1,1,2)(2,1,2)_{12}$	8	488.58	495.78	499.52
8	$\text{SARIMA}(2,1,2)(2,1,2)_{12}$	9	486.39	495.86	498.69
9	$\text{SARIMA}(2,1,2)(1,1,2)_{12}$	8	490.78	497.98	501.72
10	$\text{SARIMA}(0,1,1)(0,1,2)_{12}$	4	502.02	503.62	507.63
11	$\text{SARIMA}(1,1,1)(0,1,2)_{12}$	5	502.71	505.21	509.72
12	$\text{SARIMA}(0,1,1)(1,1,2)_{12}$	5	503.82	506.32	510.83
13	$\text{SARIMA}(2,1,0)(2,1,0)_{12}$	5	504.87	507.37	511.88
14	$\text{SARIMA}(1,1,1)(1,1,2)_{12}$	6	503.86	507.51	512.27
15	$\text{SARIMA}(2,1,1)(0,1,2)_{12}$	6	504.55	508.20	512.96
16	$\text{SARIMA}(0,1,1)(2,1,2)_{12}$	6	504.58	508.23	512.99
17	$\text{SARIMA}(1,1,1)(2,1,2)_{12}$	7	503.81	508.90	513.61
18	$\text{SARIMA}(2,1,0)(2,1,1)_{12}$	6	505.31	508.96	513.71
19	$\text{SARIMA}(2,1,1)(2,1,0)_{12}$	6	505.51	509.16	513.92
20	$\text{SARIMA}(2,1,0)(2,1,2)_{12}$	7	505.70	510.80	515.51
21	$\text{SARIMA}(2,1,1)(1,1,2)_{12}$	7	505.72	510.81	515.53
22	$\text{SARIMA}(2,1,2)(2,1,0)_{12}$	7	506.81	511.90	516.62
23	$\text{SARIMA}(2,1,2)(2,1,1)_{12}$	8	505.70	512.56	516.91
24	$\text{SARIMA}(2,1,1)(2,1,2)_{12}$	8	505.79	512.65	517.00
25	$\text{SARIMA}(2,1,1)(2,1,1)_{12}$	7	508.89	513.98	518.70
26	$\text{SARIMA}(0,1,0)(0,1,2)_{12}$	3	521.08	521.96	525.38
27	$\text{SARIMA}(1,1,0)(2,1,0)_{12}$	4	522.37	523.91	528.11
28	$\text{SARIMA}(1,1,0)(0,1,2)_{12}$	4	522.46	523.99	528.19
29	$\text{SARIMA}(1,1,1)(2,1,0)_{12}$	5	521.79	524.19	528.96
30	$\text{SARIMA}(0,1,0)(1,1,2)_{12}$	4	522.81	524.35	528.55
31	$\text{SARIMA}(1,1,2)(2,1,0)_{12}$	6	521.14	524.64	529.74
32	$\text{SARIMA}(2,1,0)(0,1,2)_{12}$	5	523.13	525.53	530.30
33	$\text{SARIMA}(1,1,0)(2,1,1)_{12}$	5	523.28	525.68	530.45
34	$\text{SARIMA}(1,1,0)(1,1,2)_{12}$	5	523.73	526.13	530.90
35	$\text{SARIMA}(1,1,2)(2,1,1)_{12}$	7	521.40	526.27	531.43
36	$\text{SARIMA}(0,1,0)(2,1,2)_{12}$	5	524.12	526.52	531.29
37	$\text{SARIMA}(2,1,0)(1,1,2)_{12}$	6	523.57	527.07	532.18
38	$\text{SARIMA}(1,1,1)(2,1,1)_{12}$	6	523.95	527.45	532.56
39	$\text{SARIMA}(1,1,0)(2,1,2)_{12}$	6	525.20	528.70	533.81
40	$\text{SARIMA}(0,1,0)(2,1,0)_{12}$	3	537.74	538.59	542.13

componente sazonal de médias móveis.

O conjunto inclui um modelo de referência mais parcimonioso, SARIMA$(0,1,0)(0,1,1)_{12}$, bem como extensões progressivamente mais flexíveis: SARIMA$(0,1,0)(0,1,2)_{12}$ e SARIMA$(0,1,1)(0,1,1)_{12}$, SARIMA$(0,1,1)(0,1,2)_{12}$ e SARIMA$(0,1,2)(0,1,2)_{12}$ — este último o modelo com melhor desempenho de AICc, de acordo com a Tabela 4. Esta comparação permite avaliar explicitamente se a introdução de termos adicionais de médias móveis, tanto na componente não sazonal como na sazonal, conduz a melhorias significativas no ajuste do modelo e nos diagnósticos dos resíduos.

Os modelos são estimados pelo método da máxima verossimilhança por meio do filtro de Kalman, conforme implementado no `statsmodels` [9]. Os resultados são apresentados na Tabela 5.

Tabela 5. Comparação dos modelos candidatos após estimação.

Modelo SARIMA (p,d,q) $(P,D,Q)_1$	**Parâ**	**AIC**	**BIC**	**Significância dos parâmetros**	**Invertibilidade**	**Diagnósticos**
(0,1,0) (0,1,1)	2	724	728	Θ_1 significativo ($p < 0.001$)	Invertível ($\hat{\Theta}_1 = -0.372$)	Ljung–Box marginal ($p = 0.07$); sem evidência de heterocedasticidade ($p = 0.59$)
(0,1,1) (0,1,1)	3	704	709	MA_1 significativo ($p < 0.001$); Θ_1 significativo ($p = 0.005$)	Invertível ($\hat{\Theta}_1 = -0.336$)	Ljung–Box não rejeita independência ($p = 0.75$); sem evidência de heterocedasticidade ($p = 0.09$)
(0,1,0) (0,1,2)	3	522	525	Θ_1 significativo ($p = 0.012$); Θ_2 não significativo ($p = 0.511$)	Próximo da fronteira ($\hat{\Theta}_1 = -0.958$)	Ljung–Box não rejeita independência ($p = 0.21$); sem evidência de heterocedasticidade ($p = 0.24$)
(0,1,1) (0,1,2)	4	504	508	MA_1 significativo ($p = 0.037$); Θ_1 marginal ($p = 0.056$); Θ_2 não significativo ($p = 0.581$)	Estimativa próxima da fronteira ($\hat{\Theta}_1 = -1.063$)	Ljung–Box não rejeita independência ($p = 0.71$); evidência de heterocedasticidade ($p = 0.01$)
(0,1,2) (0,1,2)	5	490	494	MA_1 marginal ($p = 0.082$); MA_2 não significativo ($p = 0.255$); Θ_1 marginal ($p = 0.053$); Θ_2 não significativo ($p = 0.507$)	Estimativa próxima da fronteira ($\hat{\Theta}_1 = -1.021$)	Ljung–Box não rejeita independência ($p = 0.87$); evidência de heterocedasticidade ($p = 0.02$)

A comparação dos cinco modelos candidatos revela um padrão claro de *trade-off* entre qualidade de ajuste segundo os critérios de informação e adequação global do modelo em termos de diagnósticos, significância dos parâmetros e estabilidade das estimativas. A Tabela 5 sintetiza os resultados obtidos, permitindo uma avaliação conjunta destes critérios.

Modelos com componente sazonal de ordem $Q = 2$

Os três modelos com $Q = 2$ — SARIMA$(0,1,0)(0,1,2)_{12}$, SARIMA$(0,1,1)(0,1,2)_{12}$ e SARIMA$(0,1,2)(0,1,2)_{12}$ — apresentam valores de AICc substancialmente inferiores aos modelos com $Q = 1$, sugerindo à partida um melhor ajuste à estrutura de autocorrelação sazonal da série. No entanto, uma análise mais cuidada revela um conjunto consistente de fragilidades que compromete a sua adequação como modelos finais.

Em todos os modelos com $Q = 2$, a estimativa de Θ_1 situa-se próximo ou além da fronteira de invertibilidade ($\hat{\Theta}_1 \in \{-0.958, -1.063, -1.021\}$), o que constitui um sinal de instabilidade numérica e potencial sobreparametrização da componente sazonal. Este padrão sistemático, comum a todas as especificações com $Q = 2$, sugere que o segundo termo sazonal de médias móveis está a capturar ruído amostral em vez de estrutura genuína do processo subjacente — um sintoma clássico de sobreparametrização. Adicionalmente, em nenhum destes modelos a totalidade dos parâmetros é estatisticamente significativa: Θ_2 é não significativo em todos os casos, e os parâmetros não sazonais apresentam valores-p que variam entre marginais e claramente não significativos. Os modelos SARIMA$(0,1,1)(0,1,2)_{12}$ e SARIMA$(0,1,2)(0,1,2)_{12}$ apresentam ainda evidência de heterocedasticidade nos resíduos ($p = 0.01$ e $p = 0.02$, respectivamente), o que compromete a validade dos intervalos de previsão. O modelo SARIMA$(0,1,0)(0,1,2)_{12}$, embora sem heterocedasticidade, é o mais parcimonioso do grupo mas apresenta AICc de 521.96, consideravelmente superior aos restantes modelos com $Q = 2$, sem que os seus diagnósticos justifiquem a preferência face às alternativas com componente não sazonal.

Face a este conjunto de evidências, os modelos com $Q = 2$ são preteridos, não obstante os seus valores de AICc mais favoráveis. A vantagem em termos de critério de informação é interpretada como resultado de sobreparametrização, e não de uma genuína melhoria na representação do processo estocástico subjacente.

Modelos com componente sazonal de ordem $Q = 1$

Os modelos SARIMA$(0,1,0)(0,1,1)_{12}$ e SARIMA$(0,1,1)(0,1,1)_{12}$ apresentam estimativas de Θ_1 bem afastadas da fronteira de invertibilidade ($\hat{\Theta}_1 = -0.372$ e $\hat{\Theta}_1 = -0.336$,

respectivamente), todos os parâmetros estatisticamente significativos, e ausência de evidência de heterocedasticidade. O modelo SARIMA$(0,1,0)(0,1,1)_{12}$, porém, apresenta o teste de Ljung–Box marginalmente significativo ($p = 0.07$), indiciando autocorrelação residual não totalmente capturada pela especificação puramente sazonal. A introdução do termo MA_1 no modelo SARIMA$(0,1,1)(0,1,1)_{12}$ resolve esta limitação, com o teste de Ljung–Box a não rejeitar a independência dos resíduos ($p = 0.75$), sem comprometer nenhum dos restantes critérios de adequação.

Modelo seleccionado

O modelo seleccionado é o SARIMA$(0,1,1)(0,1,1)_{12}$, com base na avaliação conjunta dos seguintes critérios:

1. **Significância dos parâmetros**: todos os parâmetros estimados são estatisticamente significativos, nomeadamente MA_1 ($p < 0.001$) e Θ_1 ($p = 0.005$), o que não se verifica em nenhum dos modelos com $Q = 2$.

2. **Invertibilidade**: as estimativas encontram-se bem dentro da região de invertibilidade ($\hat{\Theta}_1 = -0.336$), contrastando com os valores próximos ou além da fronteira observados em todos os modelos com $Q = 2$.

3. **Homocedasticidade dos resíduos**: o teste de heterocedasticidade não rejeita a hipótese de variância constante ($p = 0.09$), garantindo a validade dos intervalos de previsão.

4. **Independência dos resíduos**: o teste de Ljung–Box não rejeita a hipótese de independência ($p = 0.75$), confirmando que a estrutura de dependência da série é adequadamente capturada pelo modelo.

5. **Parcimónia**: com apenas três parâmetros, o modelo satisfaz o princípio da parcimónia, evitando o risco de sobreparametrização evidenciado pelos modelos com $Q = 2$.

Reconhece-se que o SARIMA$(0,1,1)(0,1,1)_{12}$ apresenta um AICc substancialmente superior ao dos modelos com $Q = 2$. No entanto, esta desvantagem é interpretada à luz do padrão sistemático de instabilidade observado naqueles modelos — estimativas na fronteira de invertibilidade, parâmetros não significativos e heterocedasticidade residual — que sugere colectivamente que a melhoria de AICc resulta de sobreparametrização e não de uma representação genuinamente superior do processo gerador dos dados. Num contexto de Box–Jenkins, em que a validade do modelo assenta na adequação dos diagnósticos e na interpretabilidade dos parâmetros, o critério de informação é considerado condição necessária mas não suficiente para a selecção final.

4.3. Estimação do Modelo Selecionado

O modelo seleccionado, SARIMA$(0,1,1)(0,1,1)_{12}$, é estimado pelo método da máxima verossimilhança por meio do filtro de Kalman, conforme implementado no `statsmodels` [9]. Os resultados são apresentados na Tabela 6.

Tabela 6. Estimativas dos parâmetros do modelo SARIMA$(0,1,1)(0,1,1)_{12}$.

Parâmetro	**Estimativa**	**Erro-padrão**	**IC 95%**	**Valor-p**
θ_1 (MA$_1$)	-0.5304	0.128	$[-0.782,\ -0.279]$	< 0.001
Θ_1 (SMA$_1$)	-0.3356	0.119	$[-0.569,\ -0.102]$	0.005
σ^2	$9.06 \cdot 10^5$	$1.91 \cdot 10^5$	$[5.32 \cdot 10^5,\ 1.28 \cdot 10^6]$	< 0.001

4.4. Diagnóstico dos Resíduos

O diagnóstico do modelo ajustado é realizado por meio de quatro gráficos: (i) série temporal dos resíduos padronizados, (ii) FAC dos resíduos, (iii) histograma com curva $\mathcal{N}(0,1)$ sobreposta, e (iv) QQ-plot. Um modelo adequado deve produzir resíduos sem padrão sistemático, sem autocorrelação e distribuição aproximadamente normal [7, Capítulo 8].

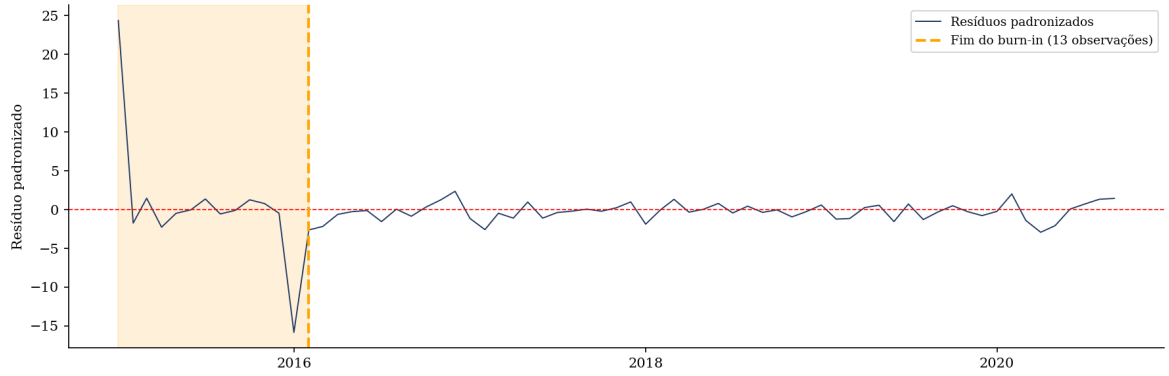


Figura 6. Resíduos padronizados do modelo SARIMA$(0,1,1)(0,1,1)_{12}$ ajustado ao longo do tempo. São apresentadas todas as observações, incluindo o período inicial de *burn-in* de 13 observações, assinalado por uma linha vertical.

Nota metodológica sobre o cálculo dos resíduos. O modelo SARIMA$(0,1,1)(0,1,1)_{12}$ implica uma diferenciação regular de ordem $d = 1$ e uma diferenciação sazonal de ordem $D = 1$ com período sazonal $s = 12$. O filtro de Kalman utilizado na estimação por máxima verossimilhança requer um período de inicialização (*burn-in*) de $d + D \times s = 1 + 1 \times 12 = 13$ observações antes de produzir erros de previsão a um passo genuínos. Durante este período inicial, os resíduos não correspondem a erros de previsão reais, mas sim a artefactos numéricos associados à inicialização do filtro. A

evolução completa dos resíduos, incluindo o período de *burn-in*, pode ser observada na Figura 6.

Por este motivo, as primeiras 13 observações são excluídas da análise de diagnóstico, resultando numa amostra de $n = 56$ resíduos padronizados válidos (fevereiro de 2016 a setembro de 2020). Esta prática é consistente com o procedimento interno do `statsmodels`, que para modelos sem componente autorregressiva ($p = P = 0$) remove automaticamente as primeiras $d + D \times s$ observações nos seus testes de diagnóstico.

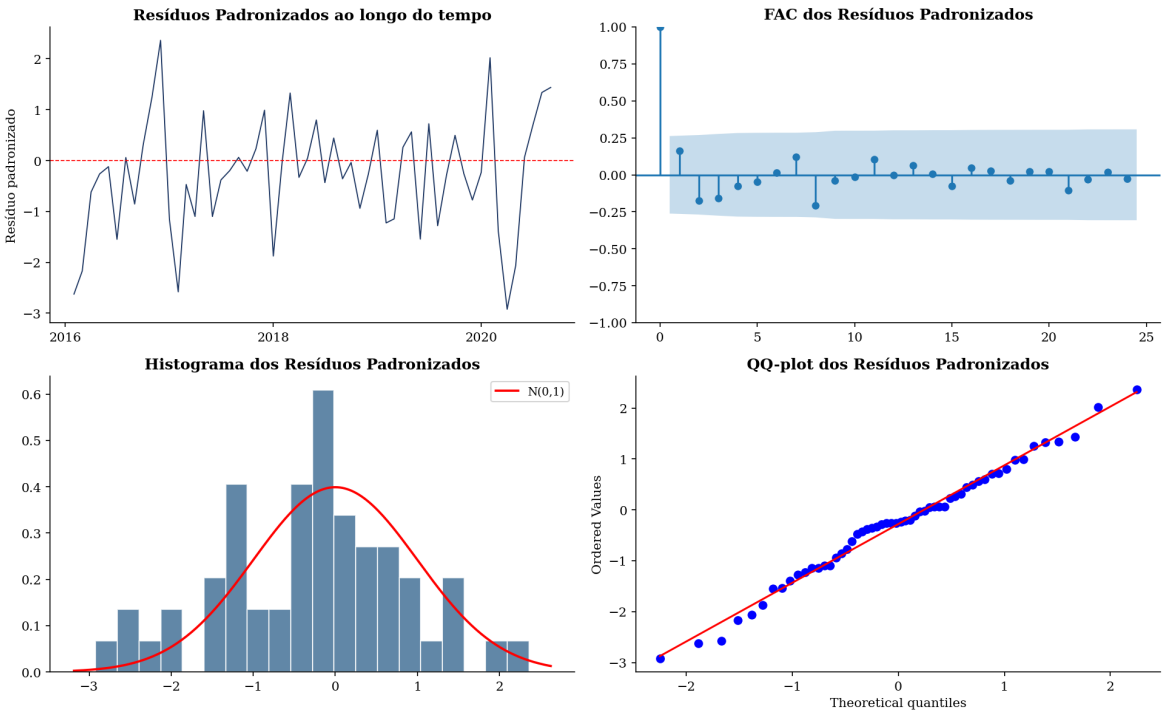


Figura 7. Diagnóstico dos resíduos padronizados do modelo SARIMA$(0,1,1)(0,1,1)_{12}$ ajustado ($n = 56$, após exclusão das 13 observações de *burn-in*). Os painéis mostram (da esquerda para a direita, de cima para baixo): série temporal dos resíduos padronizados, FAC, histograma com curva $\mathcal{N}(0,1)$ sobreposta e QQ-plot.

A Figura 7 apresenta os quatro painéis de diagnóstico dos resíduos padronizados do modelo SARIMA$(0,1,1)(0,1,1)_{12}$, após exclusão do período de *burn-in* de 13 observações. Os resultados dos testes formais são resumidos na Tabela 7.

Tabela 7. Resultados dos testes formais de diagnóstico dos resíduos padronizados ($n = 56$, após exclusão do *burn-in*).

Teste	**Hipótese Nula**	**Estat. / p-valor**	**Conclusão**
Ljung-Box ($\ell = 12$)	Sem autocorrelação	$Q = 10.20,\ p = 0.598$	Não rejeita H_0
Ljung-Box ($\ell = 24$)	Sem autocorrelação	$Q = 12.65,\ p = 0.972$	Não rejeita H_0
Shapiro-Wilk	Normalidade	$W = 0.99,\ p = 0.847$	Não rejeita H_0
Jarque-Bera	Normalidade	$JB = 0.24,\ p = 0.886$	Não rejeita H_0
ARCH-LM	Sem efeitos ARCH	$stat = 9.79,\ p = 0.549$	Não rejeita H_0

Resíduos ao longo do tempo. O painel superior esquerdo mostra os resíduos padronizados ao longo do período amostral (fevereiro de 2016 a setembro de 2020). Os resíduos oscilam em torno de zero sem tendência sistemática visível, o que é consistente com a hipótese de média zero. Observam-se, contudo, alguns valores extremos de maior magnitude, que sugerem a presença de observações atípicas pontuais. A amplitude das flutuações não aparenta ser estritamente constante ao longo do tempo — com um período de maior volatilidade em 2016–2017 seguido de relativa estabilidade — embora o teste ARCH-LM não rejeite a hipótese de ausência de efeitos ARCH ($stat = 9.79,\ p = 0.549$), pelo que esta variação visual não é estatisticamente significativa ao nível de 5%.

Função de Autocorrelação dos resíduos. O painel superior direito apresenta a FAC dos resíduos padronizados até ao desfasamento 25. À excepção do desfasamento zero (que é trivialmente igual a 1 por construção), todos os coeficientes de autocorrelação se encontram dentro das bandas de confiança a 95%, sem qualquer padrão sistemático de cortes ou decaimentos que indicie estrutura de dependência remanescente. Em particular, não se observam picos significativos nos desfasamentos sazonais (12 e 24), confirmando que a componente sazonal foi adequadamente capturada pelo modelo. Este resultado é corroborado pelos testes de Ljung–Box, que não rejeitam a hipótese de independência dos resíduos para ambos os horizontes considerados ($Q = 10.20,\ p = 0.598$ para $\ell = 12$; $Q = 12.65,\ p = 0.972$ para $\ell = 24$).

Histograma e distribuição normal. O painel inferior esquerdo sobrepõe o histograma dos resíduos padronizados à densidade de uma distribuição normal padrão $\mathcal{N}(0, 1)$. A distribuição empírica apresenta uma concentração central próxima do esperado, com ligeira assimetria negativa e cauda esquerda algo mais pesada do que o previsto pela normal — visível na barra à esquerda de -2. O desvio observado não é,

porém, estatisticamente significativo: o teste de Jarque–Bera não rejeita a hipótese de normalidade ($JB = 0.24,\ p = 0.886$), resultado confirmado pelo teste de Shapiro–Wilk ($W = 0.99,\ p = 0.847$).

QQ-plot. O painel inferior direito compara os quantis empíricos dos resíduos com os quantis teóricos da distribuição normal padrão. Os pontos alinham-se de forma satisfatória ao longo da recta de referência na região central, com algum afastamento nas caudas — particularmente na cauda esquerda, onde se observam dois ou três pontos abaixo da recta, correspondentes aos valores extremos identificados no painel temporal. Este padrão é consistente com a ligeira assimetria negativa observada no histograma, mas não é suficientemente pronunciado para comprometer a validade da inferência, conforme confirmado pelos testes de Jarque–Bera e Shapiro–Wilk.

Síntese diagnóstica. Em conjunto, os quatro painéis e os testes formais apresentados na Tabela 7 suportam a adequação do modelo SARIMA$(0,1,1)(0,1,1)_{12}$ como representação do processo gerador dos dados. Os resíduos são consistentes com a hipótese de ruído branco gaussiano: os testes de Ljung–Box não detectam autocorrelação significativa para nenhum dos horizontes considerados, os testes de Jarque–Bera e Shapiro–Wilk não rejeitam a normalidade, e o teste ARCH-LM não encontra evidência de heterocedasticidade condicional. Os valores extremos pontuais observados poderão reflectir choques exógenos na procura de energia eléctrica não capturáveis pela estrutura linear do modelo, mas a sua influência não é suficiente para invalidar os diagnósticos globais.

5. Extensão do Modelo: Análise de Intervenção

A análise de intervenção, proposta por Box, Jenkins e Reinsel [3, Capítulo 9] e descrita em Morettin e Toloi [7, Capitulo 12], permite incorporar o efeito de eventos exógenos discretos dentro do arcabouço SARIMA. Uma vez que o período de análise inclui os primeiros meses da pandemia de COVID-19 (março–setembro de 2020), é possível avaliar este evento como uma intervenção estrutural na série.

Duas abordagens complementares são apresentadas. A primeira (Secção 5.1.1) incorpora uma variável de pulso diretamente num modelo estimado sobre toda a amostra, constituindo uma verificação preliminar. A segunda (Secção 5.1.2) estima o modelo SARIMA exclusivamente no período pré-pandemia e avalia o efeito da COVID-19 por meio da discrepância entre os valores observados e as previsões geradas para o período março–setembro de 2020 — uma abordagem mais robusta, uma vez que o modelo base não é contaminado pelo próprio choque que se pretende detetar.

5.1. Verificação Preliminar

5.1.1 Modelo de Intervenção com Amostra Completa (pulso em março de 2020)

Como primeira verificação, especifica-se um modelo SARIMAX com uma variável de pulso unitário em março de 2020, estimado sobre a totalidade da amostra (2015–2020):

$$Y_t = \omega\, P_t^{(2020:03)} + N_t, \qquad N_t \sim \text{SARIMA}(0,1,1)(0,1,1)_{12}, \tag{1}$$

onde $P_t^{(2020:03)}$ é a variável de pulso unitário em março de 2020 e ω mede a magnitude da queda instantânea no consumo.

Tabela 8. Estimativas do modelo SARIMAX com intervenção, amostra completa (pulso mar/2020, COVID-19).

Parâmetro	**Estimativa**	**Erro-padrão**	**IC 95%**	**Valor-p**
ω (pulso mar/2020, COVID-19)	86.7410	585.401	$[-1060.62,\ 1234.11]$	0.882
θ_1 (MA_1)	-0.5296	0.144	$[-0.812,\ -0.247]$	< 0.001
Θ_1 (SMA_1)	-0.3350	0.119	$[-0.569,\ -0.101]$	0.005
σ^2	9.053×10^5	2.1×10^5	$[4.94\times10^5,\ 1.32\times10^6]$	< 0.001

Como mostrado na Tabela 8, a estimação não fornece evidência estatística de um efeito de intervenção pontual: $\hat{\omega} = 86.7410$, com valor-$p = 0.882$ e um intervalo de confiança de 95% que inclui amplamente o zero.

A comparação dos critérios de informação indica uma ligeira piora do ajuste com a inclusão da intervenção (AIC sem intervenção: 703.86; com intervenção: 705.81). Assim, a inclusão do pulso não é suportada pelos dados nesta especificação.

Importa, no entanto, notar uma limitação metodológica desta verificação preliminar: os parâmetros do modelo SARIMA (N_t) foram estimados conjuntamente com ω sobre toda a série, incluindo o próprio período pós-COVID. Isto significa que a estrutura ARMA/sazonal pode parcialmente absorver o choque pandémico durante a estimação, atenuando a magnitude e a significância estimadas do efeito de pulso — um problema de confundimento entre os parâmetros estruturais do modelo e o próprio efeito de intervenção que se pretende isolar. Por este motivo, esta verificação é tratada como exploratória, e uma abordagem mais robusta é apresentada na Secção 5.1.2.

5.1.2 Teste de Intervenção via Modelo Pré-COVID

Para evitar que o próprio choque pandémico influencie a estimação da estrutura de base, o modelo SARIMA$(0,1,1)(0,1,1)_{12}$ é reestimado utilizando exclusivamente as observações do período pré-COVID (janeiro de 2015 a fevereiro de 2020, $N = 62$). A partir deste modelo, geram-se previsões para os 7 meses seguintes (março–setembro de 2020), que constituem o contrafactual "o que se esperaria observar na ausência da pandemia". O efeito da intervenção é avaliado pela discrepância entre os valores observados e este contrafactual, em relação aos intervalos de previsão a 95%.

Os resultados da estimação são apresentados na Tabela 9. Os parâmetros estimados são estatisticamente significativos: $\hat{\theta}_1 = -0.677$ ($p < 0.001$) e $\hat{\Theta}_1 = -0.364$ ($p = 0.002$), com intervalos de confiança a 95% inteiramente contidos na região de invertibilidade. Comparativamente ao modelo estimado na amostra completa ($\hat{\theta}_1 = -0.530$, $\hat{\Theta}_1 = -0.336$), os parâmetros mantêm o mesmo sinal e ordem de grandeza, sendo a diferença mais pronunciada em θ_1, o que é esperado dado que a amostra completa inclui o período pandémico, caracterizado por choques abruptos na procura que atenuam a componente de médias móveis não sazonal. A variância estimada, $\hat{\sigma}^2 = 5.53 \times 10^5$, é inferior à da amostra completa (9.06×10^5), reflectindo a maior homogeneidade do período pré-pandémico e constituindo um indício adicional de que o choque de 2020 representa uma ruptura estrutural relativamente ao padrão histórico.

Os diagnósticos dos resíduos, sintetizados na Tabela 10, não revelam qualquer inadequação do modelo no período pré-COVID. O teste de Ljung–Box não detecta autocorrelação significativa, o teste de Jarque–Bera não rejeita a normalidade dos resíduos, e o teste de heterocedasticidade não encontra evidência de variância não constante. Estes resultados confirmam que o modelo estimado no período pré-COVID constitui uma representação adequada da estrutura estocástica da série antes da pandemia, validando a utilização das suas previsões como contrafactual para a análise de intervenção que se segue.

Tabela 9. Estimativas do modelo SARIMA$(0,1,1)(0,1,1)_{12}$ para a amostra pré-COVID (janeiro de 2015 a fevereiro de 2020).

Parâmetro	**Estimativa**	**Erro-padrão**	**IC 95%**	**Valor-p**
θ_1 (MA_1)	-0.6773	0.153	$[-0.978,\ -0.376]$	< 0.001
Θ_1 (SMA_1)	-0.3639	0.116	$[-0.591,\ -0.137]$	0.002
σ^2	5.525×10^5	1.64×10^5	$[2.31\times10^5,\ 8.73\times10^5]$	0.001

Tabela 10. Estatísticas de ajuste e testes diagnósticos do modelo SARIMA$(0,1,1)\times(0,1,1)_{12}$ pré-COVID.

Estatística	**Valor**	**Interpretação**
Período da amostra	Jan. 2015 – Fev. 2020	Exclui o período pandémico
Número de observações	62	Após exclusão do *burn-in* de 13 obs. ($n = 49$ resíduos válidos)
AIC	571.656	
BIC	576.322	
Teste de Ljung–Box (12 meses)	1.83 ($p = 0.18$)	Não rejeita H_0: resíduos sem autocorrelação significativa
Teste de Jarque–Bera	0.59 ($p = 0.74$)	Não rejeita H_0: resíduos compatíveis com distribuição normal
Teste de heterocedasticidade	1.24 ($p = 0.71$)	Não rejeita H_0: sem evidência de variância não constante

Os resultados da Tabela 11 mostram um padrão distinto daquele obtido na verificação preliminar baseada na amostra completa. Embora o valor observado para março de 2020 permaneça dentro do intervalo de confiança de 95% da previsão contrafactual, observa-se uma quebra clara entre abril e julho de 2020. Nos meses de abril, maio, junho e julho de 2020, os valores observados ficaram sistematicamente abaixo das previsões geradas pelo modelo estimado exclusivamente com dados pré-pandemia, excedendo o limite inferior dos respetivos intervalos de previsão de 95%.

Este resultado sugere que o impacto associado ao período inicial da pandemia não se manifesta como um choque instantâneo concentrado apenas em março de 2020, mas sim como uma perturbação distribuída ao longo de vários meses subsequentes. Observa-se também que, a partir de agosto de 2020, os valores observados voltam a situar-se dentro dos intervalos de previsão, sugerindo um processo de recuperação parcial e reaproximação ao comportamento esperado segundo a dinâmica histórica da série.

Em termos de análise de intervenção, tal comportamento é mais consistente com uma intervenção do tipo *temporária* e *gradual* do que com um efeito abrupto e permanente.

Tabela 11. Observado vs. previsão contrafactual (modelo pré-COVID), março–setembro de 2020.

Mês	Observado	Previsto	IC 95%	Desvio	Desvio %	Obs. $\in$ IC 95%
Mar/2020	41824.1	42974.7	[41517.9 , 44431.6]	−1150.6	−2.7	✓
Abr/2020	35578.6	38794.6	[37263.8 , 40325.5]	−3216.0	−8.3	×
Mai/2020	36209.8	39897.0	[38295.6 , 41498.4]	−3687.2	−9.2	×
Jun/2020	35744.7	38373.6	[36704.6 , 40042.6]	−2628.9	−6.9	×
Jul/2020	38038.2	39993.8	[38259.9 , 41727.7]	−1955.6	−4.9	×
Ago/2020	37799.0	38875.8	[37079.3 , 40672.4]	−1076.8	−2.8	✓
Set/2020	37904.5	38284.6	[36427.6 , 40141.7]	−380.1	−1.0	✓

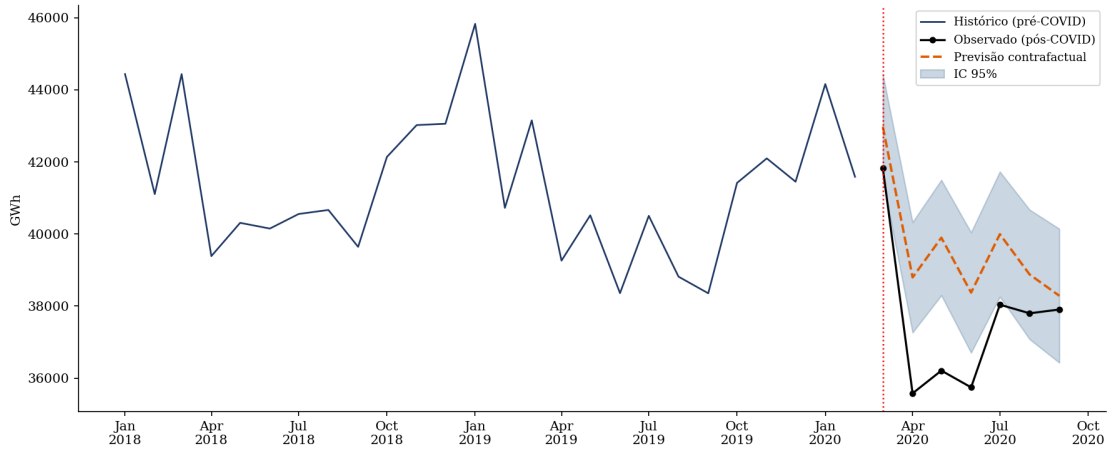


Figura 8. Consumo observado vs. previsão contrafactual do modelo pré-COVID (jan/2015–fev/2020), com IC 95%, para o período mar–set/2020.

5.2. Estimação do Modelo com Intervenção Temporária e Gradual

Os resultados da secção anterior sugerem que o efeito associado ao período inicial da pandemia não corresponde a um choque instantâneo concentrado num único instante, mas antes a uma perturbação distribuída ao longo de vários meses, seguida por uma recuperação progressiva. Em termos da metodologia para análise de intervenção, este padrão é mais consistente com uma intervenção do tipo *temporária* e *gradual* [7, Capítulo 12].

Para representar este comportamento, considera-se uma variável exógena de intervenção construída a partir de um pulso inicial em março de 2020 cujo efeito decresce geometricamente ao longo do tempo. A variável de intervenção é definida por:

$$X_t = \begin{cases} 0, & \text{se } t < T, \\ \delta^{t-T}, & \text{se } t \geq T, \end{cases}$$

onde T corresponde a março de 2020 e ($\delta \in (0, 1)$) controla a velocidade de dissipação do efeito ao longo do tempo. Valores de δ próximos de zero descrevem um retorno rápido ao comportamento histórico da série, enquanto valores próximos de um indicam maior persistência do choque.

A série observada é então modelada por:

$$Y_t = \omega X_t + N_t, \qquad N_t \sim \text{SARIMA}(0, 1, 1)(0, 1, 1)_{12},$$

onde ω representa a magnitude estimada do efeito da intervenção e N_t descreve a dinâmica estocástica residual.

A estimação foi realizada por máxima verossimilhança utilizando o modelo SARIMAX ajustado sobre toda a amostra, incorporando X_t como variável exógena. O parâmetro de persistência (δ) não foi estimado diretamente; em vez disso, foi selecionado por meio de uma busca em grelha (*grid search*) sobre o conjunto:

$$\delta \in \{0.3, 0.5, 0.6, 0.7, 0.8, 0.85, 0.9, 0.91, 0.92, 0.93, 0.94, 0.95, 0.96, 0.97, 0.98, 0.99\}.$$

Para cada valor de δ, ajustou-se um modelo distinto e compararam-se os respetivos critérios de informação, utilizando o AICc como critério principal de seleção. Esta abordagem foi adotada por razões de estabilidade numérica e devido ao reduzido número de observações disponíveis após o início da intervenção ($n = 7$).

Tabela 12. Seleção do parâmetro de persistência da intervenção por busca em grelha.

δ	$\hat{\omega}$	**Valor-p**	**AIC**	**AICc**
0.30	-344.31	0.7204	705.61	706.69
0.50	-853.47	0.6159	704.10	705.18
0.60	-1165.82	0.5371	702.49	703.58
0.70	-1499.85	0.2408	700.18	701.26
0.80	-1829.97	0.0168	697.28	698.36
0.85	-1979.66	0.0012	695.85	696.93
0.90	-2104.89	0.0000	694.80	695.88
0.91	-2125.43	0.0000	694.67	695.76
0.92	-2144.01	0.0000	694.59	695.68
0.93	-2160.40	0.0000	694.56	695.64
0.94	-2174.34	0.0000	694.57	695.65
0.95	-2185.55	0.0000	694.64	695.72
0.96	-2193.70	0.0000	694.77	695.85
0.97	-2198.48	0.0000	694.95	696.03
0.98	-2199.51	0.0000	695.19	696.28
0.99	-2196.41	0.0000	695.50	696.58

O menor valor de AICc foi obtido para ($\delta = 0.93$), indicando que o efeito associado ao período inicial da pandemia não desaparece imediatamente após março de 2020, mas se dissipa gradualmente ao longo dos meses seguintes. Este resultado encontra-se alinhado com a evidência observada na análise contrafactual, que revelou desvios persistentes entre abril e julho de 2020.

O modelo com intervenção temporária e gradual com $\delta = 0.93$ é, assim, selecionado como especificação final e será submetido à análise de diagnóstico dos resíduos na secção seguinte.

Tabela 13. Estimativas do modelo SARIMA com intervenção temporária e gradual (pulso com decaimento exponencial, $\delta = 0.93$).

Parâmetro	**Estimativa**	**Erro-padrão**	**IC 95%**	**Valor-p**
ω (decaimento COVID-19)	-2160.40	487.62	$[-3116.13,\ -1204.69]$	< 0.001
θ_1 (MA_1)	-0.6936	0.143	$[-0.975,\ -0.413]$	< 0.001
Θ_1 (SMA_1)	-0.3909	0.108	$[-0.602,\ -0.180]$	< 0.001
σ^2	6.636×10^5	1.99×10^5	$[2.74 \times 10^5,\ 1.05 \times 10^6]$	0.001

Os resultados da estimação do modelo com intervenção são apresentados na Tabela 13. Todos os parâmetros são estatisticamente significativos ao nível de 1%, com intervalos de confiança a 95% que excluem o zero em todos os casos. O parâmetro de intervenção $\hat{\omega} = -2160.40$ ($p < 0.001$) confirma um impacto inicial negativo e estatisticamente robusto da pandemia sobre a procura de energia eléctrica, com decaimento exponencial de taxa $\delta = 0.93$, sugerindo uma recuperação gradual ao longo dos meses subsequentes. Os parâmetros SARIMA mantêm o sinal e a ordem de grandeza das estimativas do modelo de base pré-COVID ($\hat{\theta}_1 = -0.694$ vs. -0.677; $\hat{\Theta}_1 = -0.391$ vs. -0.364), o que confirma a estabilidade da estrutura estocástica subjacente e a adequação da especificação de intervenção adoptada.

5.3. Diagnóstico dos Resíduos

O diagnóstico do modelo com intervenção ajustado é realizado por meio de quatro gráficos: (i) série temporal dos resíduos padronizados, (ii) FAC dos resíduos, (iii) histograma com curva $\mathcal{N}(0,1)$ sobreposta e (iv) QQ-plot. Tal como no modelo base, um modelo adequado deve produzir resíduos sem padrão sistemático, sem autocorrelação serial e com distribuição aproximadamente normal [7, Capítulo 8].

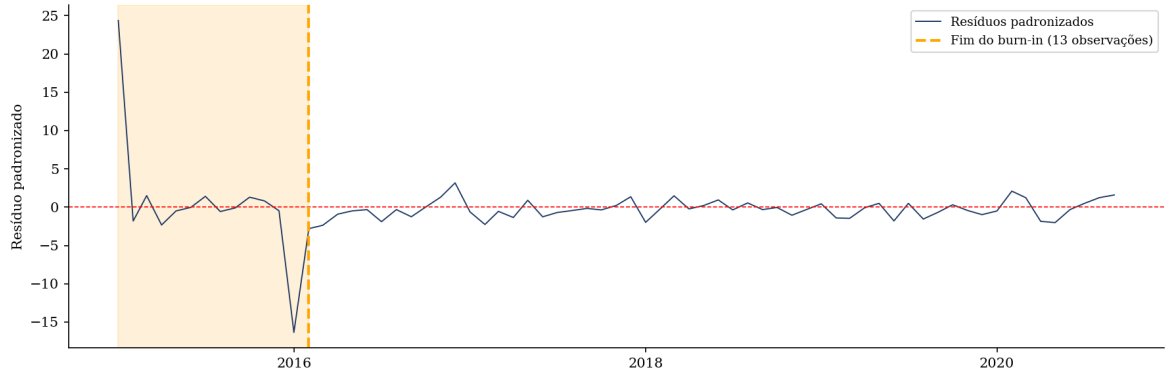


Figura 9. Resíduos padronizados do modelo SARIMA$(0,1,1)(0,1,1)_{12}$ com intervenção temporária e gradual ajustado ao longo do tempo. São apresentadas todas as observações, incluindo o período inicial de *burn-in* de 13 observações, assinalado por uma linha vertical.

Nota metodológica sobre o cálculo dos resíduos. Tal como no modelo base, o modelo SARIMA$(0,1,1)(0,1,1)_{12}$ com intervenção implica uma diferenciação regular de ordem $d = 1$ e uma diferenciação sazonal de ordem $D = 1$, com período sazonal $s = 12$. Consequentemente, o filtro de Kalman utilizado na estimação por máxima verossimilhança requer um período inicial de estabilização (*burn-in*) correspondente a $d + D \times s = 13$ observações antes de gerar erros de previsão a um passo genuínos. Durante este período inicial, os resíduos padronizados não devem ser interpretados como erros reais do modelo, mas como valores transitórios associados à inicialização do algoritmo recursivo. A Figura 9 apresenta a evolução completa dos resíduos, incluindo

este período inicial.

Por este motivo, as primeiras 13 observações são excluídas da análise de diagnóstico, resultando numa amostra final de $n = 56$ resíduos padronizados válidos (março de 2016 a setembro de 2020).

Os resultados dos testes formais são resumidos na Tabela 14, e os painéis de diagnóstico são apresentados na Figura 10.

Tabela 14. Resultados dos testes formais de diagnóstico dos resíduos padronizados ($n = 56$, após exclusão do *burn-in*) pelo modelo com intervencao.

Teste	**Hipótese Nula**	**Estat.**	***p*-valor**	**Conclusão**
Ljung-Box ($\ell = 12$)	Sem autocorrelação	$Q = 10.44$	0.577	Não rejeita H_0
Ljung-Box ($\ell = 24$)	Sem autocorrelação	$Q = 12.23$	0.977	Não rejeita H_0
Shapiro-Wilk	Normalidade	$W = 0.984$	0.652	Não rejeita H_0
Jarque-Bera	Normalidade	$JB = 1.04$	0.595	Não rejeita H_0
ARCH-LM	Sem efeitos ARCH	$stat = 9.93$	0.536	Não rejeita H_0

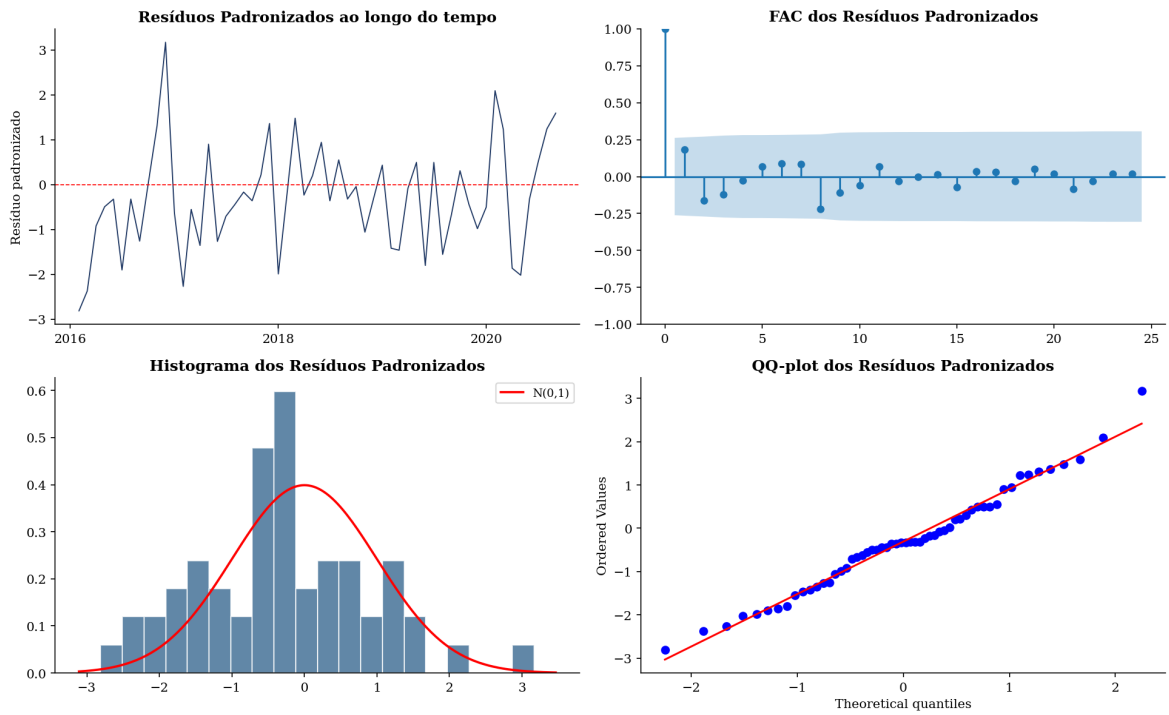


Figura 10. Diagnóstico dos resíduos padronizados do modelo SARIMA$(0,1,1)(0,1,1)_{12}$ com intervenção temporária e gradual ($n = 56$, após exclusão das 13 observações de *burn-in*). Os painéis mostram (da esquerda para a direita, de cima para baixo): série temporal dos resíduos padronizados, FAC, histograma com curva $\mathcal{N}(0,1)$ sobreposta e QQ-plot.

Resíduos ao longo do tempo. O painel superior esquerdo mostra os resíduos padronizados ao longo do período amostral (fevereiro de 2016 a setembro de 2020). Os resíduos oscilam em torno de zero sem tendência sistemática visível, o que é consistente com a hipótese de média zero. Comparativamente ao modelo sem intervenção, a amplitude das flutuações no período pandémico é reduzida, reflectindo que o choque de 2020 é agora explicitamente modelado pela componente de intervenção e não absorvido pelos resíduos. Persistem alguns valores extremos pontuais, de natureza idêntica à observada no modelo de base, mas sem qualquer padrão sistemático. O teste ARCH-LM não rejeita a hipótese de ausência de heterocedasticidade condicional ($stat = 9.93,\ p = 0.536$), confirmando que a variação visual da amplitude não é estatisticamente significativa.

Função de Autocorrelação dos resíduos. O painel superior direito apresenta a FAC dos resíduos padronizados. Todos os coeficientes de autocorrelação se encontram dentro das bandas de confiança a 95%, sem qualquer padrão sistemático que indicie dependência residual remanescente. Em particular, não se observam picos significativos nos desfasamentos sazonais (12 e 24), confirmando que tanto a estrutura sazonal como o efeito de intervenção foram adequadamente capturados pelo modelo. Os testes de Ljung–Box não rejeitam a hipótese de independência dos resíduos para ambos os horizontes considerados ($Q = 10.44,\ p = 0.577$ para $\ell = 12$; $Q = 12.23,\ p = 0.977$ para $\ell = 24$).

Histograma e distribuição normal. O painel inferior esquerdo sobrepõe o histograma dos resíduos padronizados à densidade de uma distribuição normal padrão $\mathcal{N}(0, 1)$. A distribuição empírica apresenta uma concentração central próxima do esperado, com ligeira assimetria negativa e cauda esquerda algo mais pesada do que a normal teórica — padrão análogo ao observado no modelo de base e igualmente associado aos valores extremos de 2016. O desvio não é estatisticamente significativo: o teste de Jarque–Bera não rejeita a normalidade ($JB = 1.04,\ p = 0.595$), resultado confirmado pelo teste de Shapiro–Wilk ($W = 0.984,\ p = 0.652$).

QQ-plot. O painel inferior direito compara os quantis empíricos dos resíduos com os quantis teóricos da distribuição normal padrão. Os pontos alinham-se de forma satisfatória ao longo da recta de referência na região central, com afastamento moderado nas caudas, em particular na cauda esquerda, onde se identificam dois ou três pontos abaixo da recta. Este padrão é consistente com a ligeira assimetria negativa observada no histograma e com os valores extremos identificados no painel temporal. O afastamento não é suficientemente pronunciado para comprometer a validade da inferência, conforme confirmado pelos testes de normalidade.

Síntese diagnóstica. Em conjunto, os quatro painéis e os testes formais da Tabela 14 confirmam a adequação do modelo com intervenção. Os resíduos são consistentes com a hipótese de ruído branco gaussiano: ausência de autocorrelação significativa, normalidade não rejeitada por dois testes independentes, e ausência de heterocedasticidade condicional. Relativamente ao modelo de base sem intervenção, os diagnósticos são globalmente equivalentes, o que era expectável dado que a especificação SARIMA subjacente é idêntica — a diferença reside unicamente na redução da magnitude dos resíduos no período pandémico, agora explicada pela componente de intervenção e não tratada como erro de previsão.

6. Comparação entre Modelos

Tabela 15. Comparação entre o modelo base e o modelo com intervenção temporária e gradual.

Modelo	Parâmetros	AIC	AICc	BIC
Sem intervenção	3	703.86	704.49	709.08
Pulso com decaimento ($\delta = 0.93$)	4	694.56	695.64	701.51

A Tabela 15 compara o modelo base SARIMA$(0,1,1)(0,1,1)_{12}$ com a sua extensão com intervenção temporária e gradual. A inclusão da componente de intervenção acrescenta um único parâmetro (ω), passando de 3 para 4 parâmetros estimados. Não obstante este aumento marginal de complexidade, todos os critérios de informação diminuem de forma consistente: o AIC reduz-se em 9.30 pontos, o AICc em 8.85 e o BIC em 7.57. A diminuição simultânea dos três critérios — incluindo o BIC, que penaliza mais severamente a complexidade — indica que a melhoria de ajuste não resulta de sobreparametrização, mas da incorporação explícita de uma componente sistemática que o modelo base tratava como erro de previsão.

Este resultado é consistente com a evidência obtida nas secções anteriores: a análise contrafactual demonstrou que os valores observados durante o período pandémico se situam fora dos intervalos de previsão a 95% do modelo pré-COVID, e a estimação do parâmetro de intervenção confirmou um impacto inicial negativo estatisticamente significativo ($\hat{\omega} = -2160.40$, $p < 0.001$) com recuperação gradual ($\delta = 0.93$). Os diagnósticos de ambos os modelos satisfazem os pressupostos de ruído branco gaussiano (Tabelas 7 e 14), pelo que a preferência pelo modelo com intervenção assenta exclusivamente na sua superior capacidade explicativa e não em diferenças de comportamento residual.

Face a esta evidência, o modelo com intervenção temporária e gradual ($\delta = 0.93$) é adoptado como especificação final.

7. Previsão

Com o modelo validado, produzem-se previsões para os 12 meses de outubro de 2020 a setembro de 2021, acompanhadas de intervalos de previsão de 80% e 95%. A Figura 11 apresenta as previsões sobrepostas à série histórica de 2018 em diante. A Tabela 16 lista os valores pontuais e os respectivos intervalos de previsão a 95%.

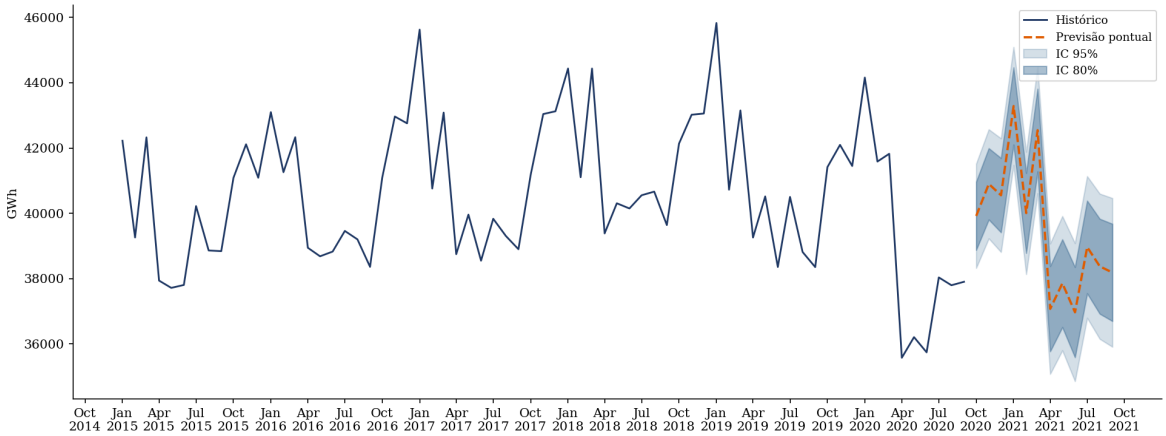


Figura 11. Previsões do consumo mensal de eletricidade em Alemanha para outubro de 2020 a setembro de 2021, com intervalos de previsão a 80% e 95%, obtidos com o modelo SARIMA$(0,1,1)(0,1,1)_{12}$ com intervenção temporária e gradual ($\delta = 0.93$).

Tabela 16. Previsões mensais do consumo de eletricidade na Alemanha (GWh).

Mês	Previsão (GWh)	IC 95% inf.	IC 95% sup.
Oct/2020	39 922.2	38 325.5	41 518.9
Nov/2020	40 900.6	39 230.6	42 570.5
Dec/2020	40 554.5	38 814.3	42 294.6
Jan/2021	43 284.2	41 476.6	45 091.8
Feb/2021	40 009.1	38 136.5	41 881.7
Mar/2021	42 546.5	40 611.0	44 481.9
Apr/2021	37 076.9	35 080.6	39 073.2
May/2021	37 857.5	35 802.1	39 912.8
Jun/2021	36 971.6	34 858.9	39 084.4
Jul/2021	38 967.1	36 798.4	41 135.7
Aug/2021	38 376.5	36 153.3	40 599.6
Sep/2021	38 188.6	35 912.2	40 464.9

8. Discussão Crítica do Modelo

8.1. Vantagens

- **Parcimônia e interpretabilidade:** a metodologia SARIMA selecciona modelos com poucos parâmetros; no caso presente, o modelo SARIMA$(0,1,1)(0,1,1)_{12}$ utiliza apenas três, tornando a interpretação directa e os intervalos de previsão bem calibrados [3];

- **Adequação à estrutura dos dados:** a série de consumo eléctrico alemão exibe as características para as quais a metodologia de Box–Jenkins foi concebida: sazonalidade regular de período fixo ($s = 12$), estacionaridade após diferenciação dupla ($d = 1$, $D = 1$) e dinâmica de curto prazo bem capturada por uma estrutura de médias móveis de ordem baixa [3];

- **Extensibilidade via análise de intervenção:** a incorporação de uma componente de intervenção com decaimento exponencial ($\delta = 0.93$) permitiu modelar explicitamente o choque pandémico de 2020, com melhoria consistente em todos os critérios de informação e parâmetros todos significativos ao nível de 1%, sem comprometer os diagnósticos de ruído branco;

- **Desempenho competitivo no curto prazo:** em horizontes de 1 a 12 meses, modelos SARIMA são frequentemente competitivos com abordagens de maior complexidade, como redes LSTM ou modelos de espaço de estados [2];

- **Infraestrutura computacional mínima:** toda a análise é executável em minutos num computador pessoal, sem necessidade de GPU ou infraestrutura de nuvem [6].

8.2. Desvantagens e Limitações

- **Linearidade:** o modelo assume relação linear entre passado e presente, não capturando assimetrias como o impacto diferenciado de ondas de calor extremas (elevação do consumo de ar condicionado) versus invernos moderados [11];

- **Amostra reduzida:** a série utilizada compreende apenas 69 observações mensais (janeiro de 2015 a setembro de 2020), o que limita o poder dos testes estatísticos, aumenta a incerteza das estimativas e restringe a capacidade do modelo para identificar padrões de longo prazo. Em particular, o período pandémico (março–setembro de 2020) representa apenas 7 observações, insuficientes para distinguir com precisão entre diferentes perfis de decaimento da intervenção;

- **Tendência não linear:** a decomposição STL da série evidencia uma tendência com perfil não linear ao longo do período amostral — crescimento gradual até um máximo aproximado de 41 500 GWh em 2018–2019, seguido de declínio acentuado até ao final da amostra (Figura 4). O operador de diferenciação regular ∇ remove tendências estocásticas localmente lineares, mas não acomoda adequadamente este tipo de curvatura de médio prazo. Parte do declínio observado a partir de 2019 poderá assim ser atribuída à tendência subjacente e não ao choque pandémico, o que introduz ambiguidade na interpretação do parâmetro de intervenção $\hat{\omega}$ e poderá conduzir a uma sobrestimação do efeito da pandemia sobre o consumo. Uma abordagem alternativa, como a decomposição STL seguida de modelação ARIMA nos resíduos da tendência, permitiria separar mais rigorosamente os dois efeitos;

  Esta não linearidade da tendência oferece também uma explicação parcial para as fragilidades observadas nos modelos com $Q = 2$: a tentativa de acomodar a curvatura de médio prazo através de termos de médias móveis adicionais poderá ter contribuído simultaneamente para a não significância individual dos parâmetros e para a heterocedasticidade residual detectada naquelas especificações.

- **Parâmetros marginalmente significativos:** o modelo com melhor desempenho segundo o AICc, SARIMA$(0,1,2)(0,1,2)_{12}$, não apresenta nenhum parâmetro estatisticamente significativo ao nível de 5%: θ_1 ($p = 0.082$), θ_2 ($p = 0.255$), Θ_1 ($p = 0.053$) e Θ_2 ($p = 0.507$). Esta fragilidade, parcialmente atribuível à não linearidade da tendência discutida acima, constituiu um dos motivos centrais

para a preterição deste modelo em favor do SARIMA$(0,1,1)(0,1,1)_{12}$, cujos parâmetros são todos significativos ao nível de 1%. Não obstante, a tensão não inteiramente resolvida entre o critério AICc — que favorece claramente a especificação com $Q = 2$ — e os critérios de diagnóstico constitui uma limitação reconhecida da abordagem adoptada;

- **Heterocedasticidade residual:** os modelos com $Q = 2$ e melhor AICc apresentaram evidência de heterocedasticidade nos resíduos ($p = 0.01$ e $p = 0.02$), comprometendo a validade dos intervalos de previsão. Como discutido acima, este resultado é consistente com a tendência não linear identificada na decomposição STL: a tentativa de acomodar a curvatura da tendência poderá ter introduzido heterocedasticidade espúria nos resíduos. O modelo seleccionado não exibe este problema, pelo que os intervalos de previsão produzidos são válidos sob os pressupostos do modelo;

- **Univariado:** variáveis climatológicas (temperatura, insolação) e macroeconômicas (PIB, preço da energia) que influenciam diretamente o consumo não são incorporadas. Um modelo de função de transferência ou ARIMAX ou SARIMAX seria mais adequado para incluir temperatura média mensal como covariável [1];

- **Sazonalidade única:** o modelo SARIMA com intervenção mantém a hipótese de uma única estrutura sazonal fixa ($s = 12$), assumindo que o padrão anual de consumo permanece aproximadamente constante ao longo de toda a série. Embora a variável de intervenção permita capturar alterações temporárias no nível da série associadas ao período inicial da pandemia, ela não modifica explicitamente a componente sazonal. Consequentemente, apesar da inclusão da componente de intervenção, o modelo SARIMA continua limitado à representação de uma única periodicidade sazonal fixa (neste estudo, $s = 12$ meses) e não consegue capturar simultaneamente múltiplas estruturas sazonais caso estas estejam presentes nos dados. Por exemplo, uma componente anual combinada com ciclos adicionais de duração intermédia (por exemplo, aproximadamente a cada 4–6 meses) ou padrões plurianuais. Nestes casos, seriam necessárias extensões do modelo ou abordagens alternativas capazes de acomodar múltiplas periodicidades [3, Capítulo 9].

- **Horizonte de previsão limitado:** a incerteza dos intervalos de previsão cresce rapidamente com h, tornando as previsões pouco informativas além de 6–12 meses [5, Capítulo 9.8].

8.3. Extensões Recomendadas

Possíveis melhorias e extensões do modelo

- **Série temporal mais longa:** a extensão da amostra a períodos anteriores a 2015 aumentaria o poder dos testes de selecção de modelo, reduziria a incerteza paramétrica e permitiria avaliar a estabilidade estrutural do modelo ao longo de ciclos económicos distintos, em particular a natureza da tendência decrescente observada a partir de 2018–2019;

- **STL + ARIMA:** dado o perfil não linear da tendência identificado na decomposição STL (Figura 4), uma abordagem alternativa consistiria na decomposição STL robusta seguida de modelação ARIMA nos resíduos da tendência. Esta estratégia separaria mais rigorosamente a componente de tendência do efeito de intervenção pandémico, reduzindo a ambiguidade na interpretação de $\hat{\omega}$ e a heterocedasticidade associada à evolução da amplitude sazonal;

- **Intervenção multi-pulso:** substituir o único pulso exponencial por uma sequência de intervenções correspondentes às diferentes vagas pandémicas e medidas de confinamento, permitindo uma representação mais fiel do impacto real da pandemia e reduzindo o risco de confusão entre o efeito da intervenção e a tendência decrescente pré-existente;

- **SARIMAX com temperatura:** incorporar a temperatura média mensal alemã (disponível no DWD – *Deutscher Wetterdienst*) como covariável exógena, capturando a relação entre clima e consumo energético;

- **SARIMA-GARCH:** os modelos SARIMA$(0,1,1)(0,1,2)_{12}$ e SARIMA$(0,1,2)(0,1,2)_{12}$, que apresentaram o melhor desempenho segundo o AICc, exibiram evidência de heterocedasticidade residual. Embora esta fragilidade tenha contribuído para a sua preterição, a sua ocorrência sistemática nos modelos com melhor ajuste sugere que a variância do processo subjacente poderá não ser estritamente constante ao longo do período amostral. Um modelo SARIMA-GARCH capturaria explicitamente esta variância condicional variante no tempo, produzindo intervalos de previsão com cobertura mais precisa independentemente da especificação adoptada para a componente de médias móveis;

- **Modelos de memória longa (ARFIMA):** séries de consumo energético frequentemente exibem persistência de longo prazo; o parâmetro de diferenciação fracionária $d \in (0,\ 0.5)$ poderia capturar este fenômeno de forma mais adequada [7];

9. Conclusão

Este trabalho apresentou uma análise completa da série mensal de consumo de eletricidade na Alemanha (janeiro de 2015 a setembro de 2020, $n = 69$), obtida do repositório OPSD/ENTSO-E, seguindo sistematicamente a metodologia de Box-Jenkins para séries temporais sazonais conforme descrita em Morettin e Toloi [7]. A série revelou as características esperadas para este tipo de dado: forte sazonalidade anual e uma intervenção identificável em 2020 associada à pandemia de COVID-19.

A aplicação sistemática das etapas de análise exploratória, testes de estacionaridade, identificação por correlogramas e critérios de informação, estimação por máxima verossimilhança e diagnóstico de resíduos conduziu à selecção do modelo SARIMA $(0, 1, 1)(0, 1, 1)_{12}$ como especificação de base. A selecção deste modelo, em detrimento do candidato com melhor AICc SARIMA$(0, 1, 2)(0, 1, 2)_{12}$, assentou na avaliação conjunta dos diagnósticos de resíduos, da significância estatística dos parâmetros e das condições de invertibilidade — critérios que aquele modelo não satisfazia de forma consistente. A extensão do modelo base com uma componente de intervenção temporária e gradual ($\delta = 0.93$) permitiu capturar explicitamente o efeito da pandemia, com melhoria consistente em todos os critérios de informação e parâmetros todos significativos ao nível de 5%. Os testes de diagnóstico aplicados aos resíduos do modelo final (Ljung–Box, Shapiro–Wilk, Jarque–Bera e ARCH-LM, Tabela 14) não rejeitam as hipóteses de ausência de autocorrelação, normalidade e homocedasticidade, confirmando a adequação da especificação adoptada.

As limitações identificadas — em particular a tendência não linear não totalmente acomodada pelo operador ∇, a natureza univariada do modelo, a reduzida dimensão amostral e a especificação de intervenção por pulso único — apontam para extensões naturais que constituem direcções relevantes para análises futuras: decomposição STL + ARIMA para separar tendência e intervenção, SARIMAX com temperatura como covariável exógena, intervenção multi-pulso e, caso a heterocedasticidade se confirme com amostras mais longas, modelação SARIMA-GARCH da variância condicional.

Referências

[1] Fj Vincent Atabay et al. “Multivariate Time Series Forecasting using ARIMAX, SARIMAX, and RNN-based Deep Learning Models on Electricity Consumption”.

Em: *2022 3rd International Informatics and Software Engineering Conference (IISEC)*. 2022, pp. 1–6.

[2] Mehmet Bilgili e Engin Pinar. "Gross electricity consumption forecasting using LSTM and SARIMA approaches: A case study of Türkiye". Em: *Energy* 284 (2023), p. 128575. issn: 0360-5442. doi: https://doi.org/10.1016/j.energy.2023.128575. url: https://www.sciencedirect.com/science/article/pii/S0360544223019692.

[3] George E. P. Box, Gwilym M. Jenkins e Gregory C. Reinsel. *Time Series Analysis*. Fourth. Wiley Series in Probability and Statistics. Forecasting and Control. John Wiley & Sons, Inc., Hoboken, NJ, 2008. isbn: 978-0-470-27284-8. doi: 10.1002/9781118619193.

[4] Ember. *Germany – Countries & Regions*. Accessed: 2026-06-10. Abr. de 2026. url: https://ember-energy.org/countries-and-regions/germany/.

[5] Rob J. Hyndman e George Athanasopoulos. *Forecasting: Principles and Practice*. 3rd. OTexts, 2021. url: https://otexts.com/fpp3/arima-forecasting.html.

[6] Spyros Makridakis, Evangelos Spiliotis e Vassilios Assimakopoulos. "Statistical and Machine Learning forecasting methods: Concerns and ways forward". Em: *PLOS ONE* 13 (mar. de 2018), pp. 1–26. doi: 10.1371/journal.pone.0194889. url: https://doi.org/10.1371/journal.pone.0194889.

[7] Pedro Alberto Morettin e Clélia Maria de Castro Toloi. *Análise de séries temporais*. 2ª ed. Edgard Blucher, 2006.

[8] Open Power System Data. *Time Series Data Package*. https://data.open-power-system-data.org/time_series/. Dados horários ENTSO-E agregados; acedido em: 2026. 2020.

[9] Skipper Seabold e Josef Perktold. "Statsmodels: Econometric and Statistical Modeling with Python". Em: (2010), pp. 92–96. doi: 10.25080/Majora-92bf1922-011.

[10] Julian Wettengel. *German grid agency projects lower need of grid management, reserve capacity next winter*. Clean Energy Wire (CLEW). Accessed: 2026-06-10. Abr. de 2025. url: https://www.cleanenergywire.org/news/german-grid-agency-projects-lower-need-grid-management-reserve-capacity-next-winter.

[11] Xi Zhang e Rui Li. "A Novel Decomposition and Combination Technique for Forecasting Monthly Electricity Consumption". Em: *Frontiers in Energy Research* Volume 9 - 2021 (2021). issn: 2296-598X. doi: 10.3389/fenrg.2021.792358. url: https://www.frontiersin.org/journals/energy-research/articles/10.3389/fenrg.2021.792358.

Para auxiliar na tradução e correção gramatical do texto, recorreu-se às ferramentas DeepL e Grammarly.

Arquivos Supplementares

Fluxograma do método do Análise

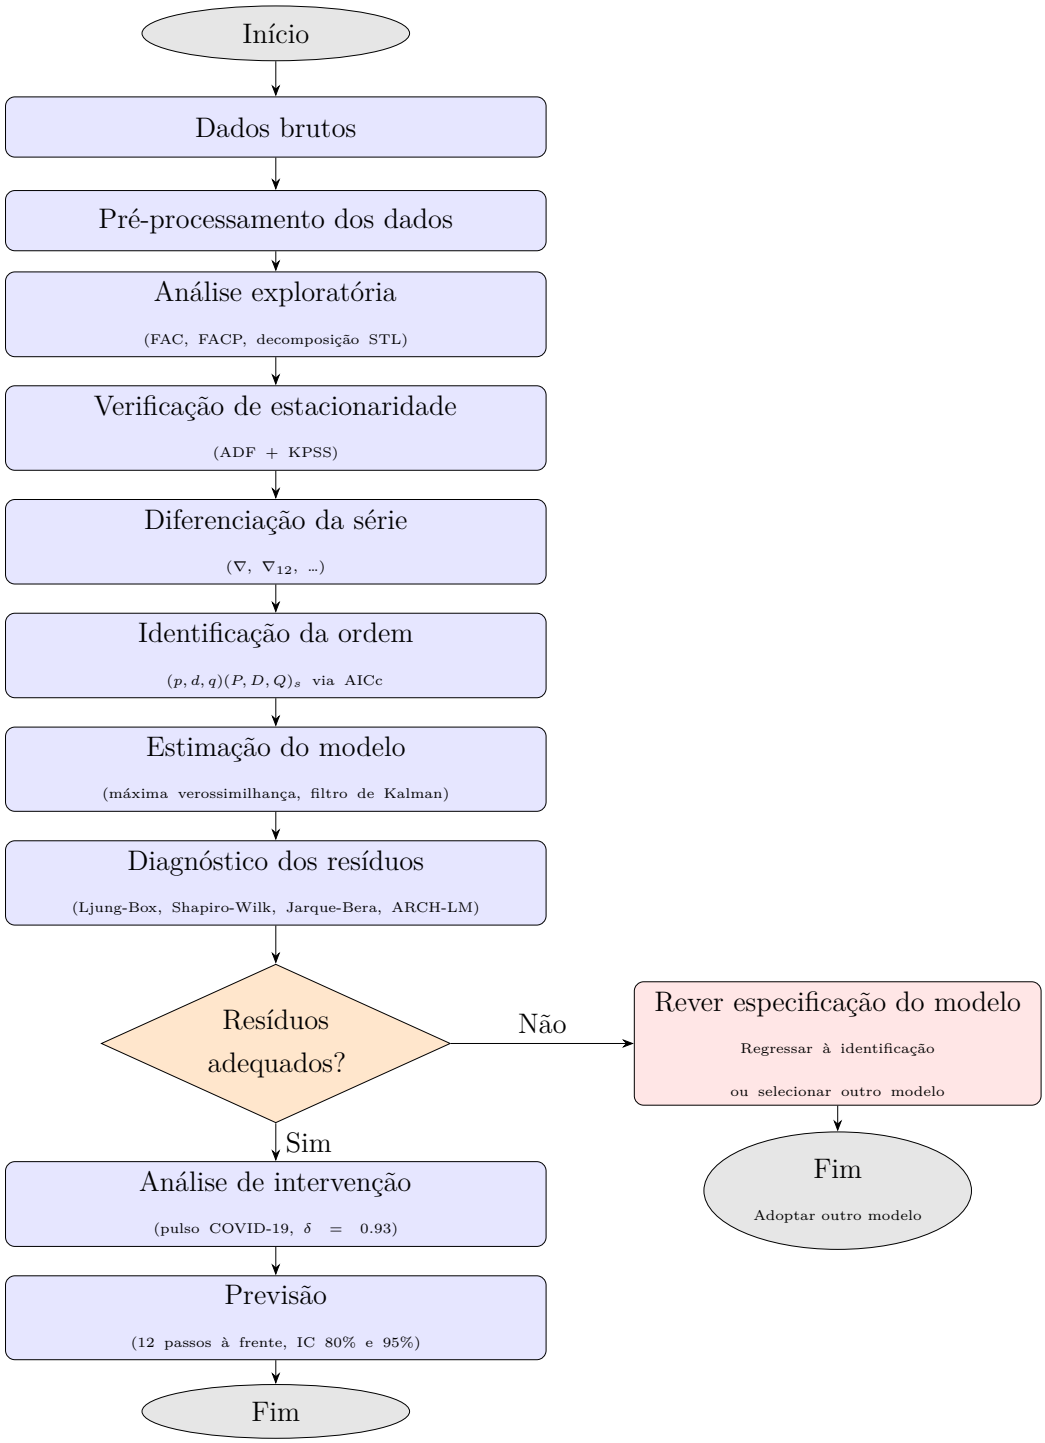


Figura 12. Fluxograma do método de análise — SARIMA com análise de intervenção

Fluxograma do algoritmo implementado no programa

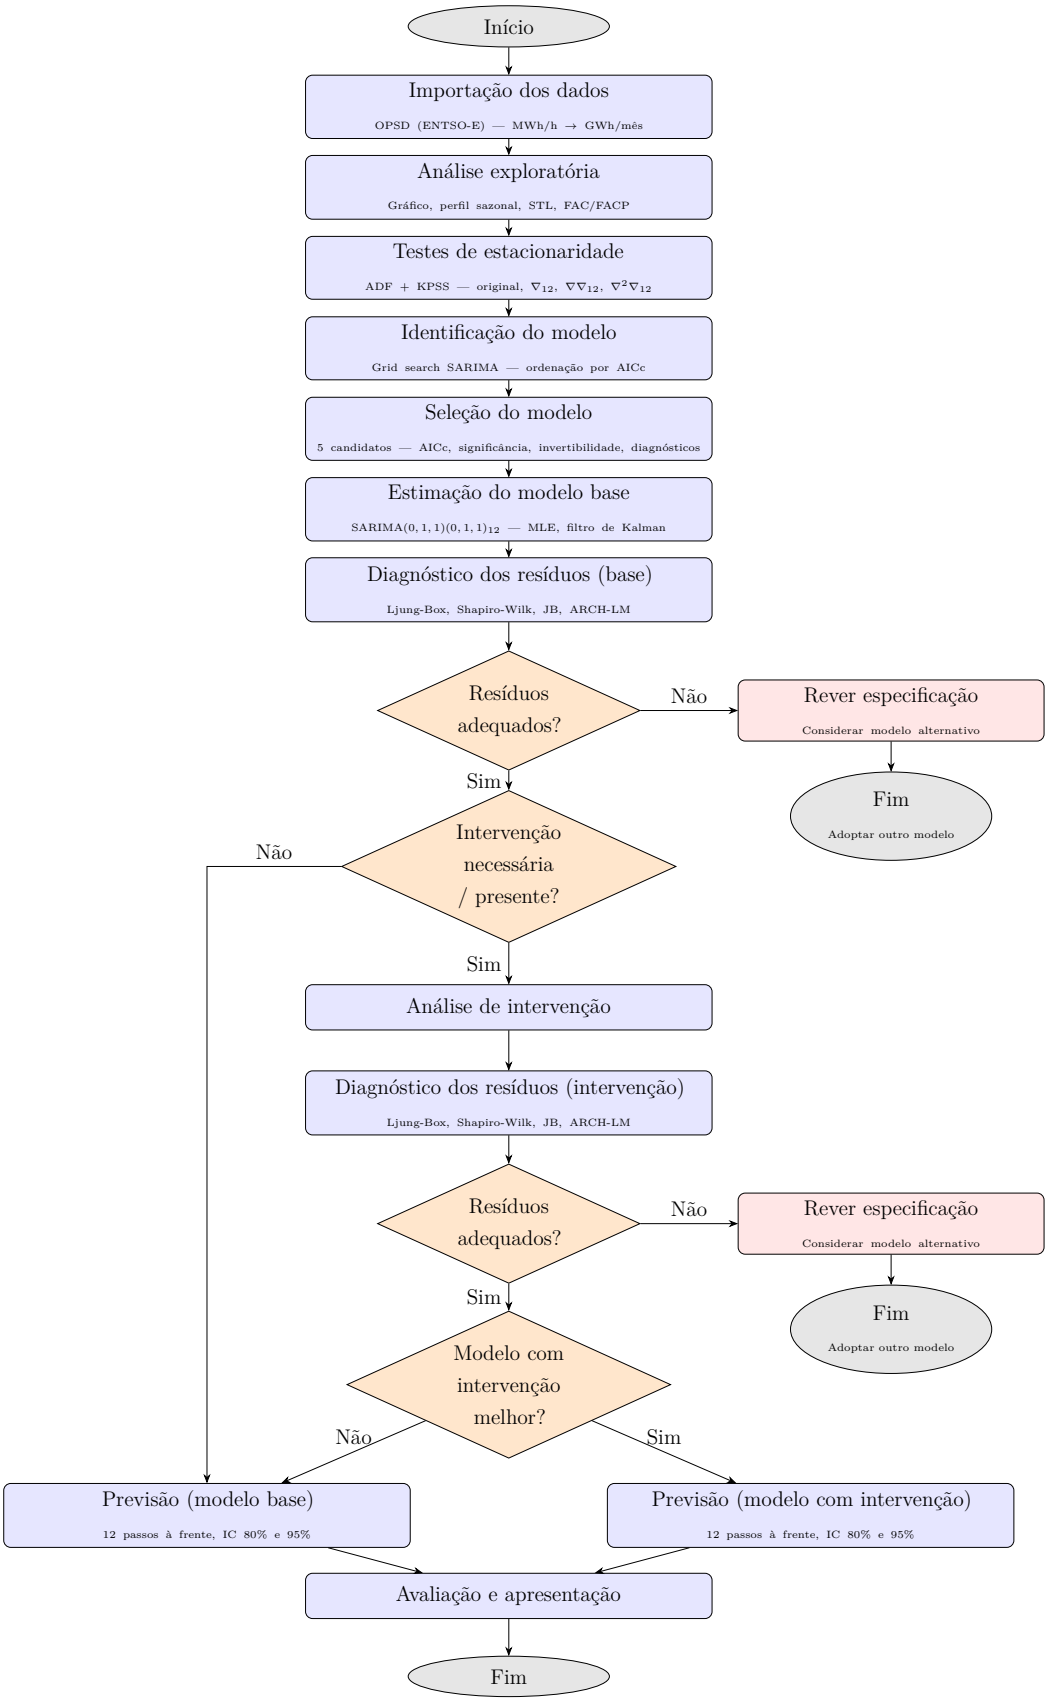


Figura 13. Fluxograma do algoritmo implementado